Scientific Validation of Narrative Detection, Channel Attribution and Measurement Uncertainty in Social — 2026

Науково-методологічний огляд і технічна специфікація

Дата зрізу літератури: 7 листопада 2026 року. **Період пріоритетних робіт:** 2018-2026. **Аудит Social:** лише читання локального checkout `a5b3a5b8f4af2398d9edd163f00708329f0fd8bc`. Репозиторій не змінювався. GitHub після цього commit не перевірявся на зміни.

Це цільовий науковий огляд із перевіркою першоджерел, а не систематичний метааналіз і не універсальний план пошуку літератури. Рецензовані статті, препринти та професійні методичні документи позначаються окремо.

Зміст

1. Executive Summary
2. Current Methodology Assessment
3. Науковий огляд: narratives, claims, stance та автоматичне кодування
4. Narrative Classification v3 - Scientific Methodology
5. Науковий огляд: атрибуція джерел та інформаційних операцій
6. Channel Classification and Attribution Framework v2
7. Науковий огляд: похибка вимірювання та невизначеність
8. Measurement Uncertainty and Robustness Framework
9. Експериментальні протоколи перевірки
10. Implementation Roadmap for Social
11. Publication Readiness
12. Перевірена наукова та методична література

1. Executive Summary

Відповідь на дослідницьке питання. Щоб кількісні результати Social стали придатнішими до рецензування, треба вимірювати тему, твердження, позицію автора та статус перевірки окремо; зберігати походження, тип суб'єкта, контент, інфраструктуру й операційні зв'язки каналу як незалежні поля; а агреговані частки поширення перевіряти спільно щодо помилок обох класифікаторів із чітким визначенням цільової сукупності.

- **Критичний недолік:** regex у `src/analysis/narratives.py` класифікує лексичні згадки, але не визначає, чи автор підтримує, заперечує, цитує або ставить твердження під сумнів. На 40 тестових постах N1/N2/N4 мають низькі метрики; еталонну розмітку надано Claude, а не незалежним людським кодуванням.
- **Канали:** у C 87 каналів, з них 61 авто-класифіковано. `auto_groups.py` знаходить інфраструктурні ознаки/російські домени й частку outbound-посилань. Це ознака для перевірки, але не доказ російського походження оператора, проросійської позиції, державного контролю чи участі в операції.
- **Частка N3:** 95,7% і 88,9% є частками за різними правилами включення міток, а не довірчими межами. Якщо обидва є частками тієї самої суми лічильників переглядів, виключений сегмент мав би близько 98,7% ваги C. Це чутливість до правил міток, не статистичний інтервал.
- **Що підтримує література:** окреме кодування claim і stance; незалежне людське подвійне кодування з арбітражем; прості супервізовані baseline-и й багатомовні трансформери як кандидати для локальної перевірки; розрізнення координації, автентичності, джерела та державної атрибуції.
- **Межі доказу:** Telegram-панель Social цільова, а не ймовірнісна. Її частки описують спостережений корпус на заданому зрізі, але не весь Telegram, унікальних людей чи громадську думку. Суму view counters не можна називати unique reach.
- **Напрям:** зберегти regex як baseline і пошук кандидатів; створити людський gold із новим кодбуком; порівняти TF-IDF + Logistic Regression/SVM, XLM-R, SetFit, NLI та pinned LLM на однакових розбиттях без витоку копій. LLM/NLI лишити вимірюваними кандидатами, не ground truth.

2. Current Methodology Assessment

2.1 Перевірені файли та межі

Перевірені локально: `src/analysis/narratives.py`, `src/analysis/validation_sample.py`, `src/analysis/auto_groups.py`, `src/analysis/analyze.py`, `src/analysis/telegram_network_dynamics.py`, `config/channel_groups.csv`, `config/channel_groups_auto.csv` і CSV перевірки з `reports/20261105T101013Z/validation/`. Зміни не вносилися. Дата й хеш визначають межу аудиту; висновки не поширюються на можливі віддалені зміни GitHub.

2.2 Що вже реалізовано правильно

- Версії regex явні, функція детермінована, допускає кілька міток; ручні й автоматичні мітки каналів зберігаються окремо, ручна має пріоритет.
- `validation_sample.py` використовує seed, випадковий відбір, виключає URL dev-набору та розділяє файл для кодування від автоматичних міток. Це добра інженерна основа для аудиту.
- `analyze.py` не підміняє поточні views історичними: `views_accumulated_before_cutoff=None`. Варто зберегти це застереження.
- Перестановочні тести й Holm correction уже є для конкретних null models. Їх не треба переписувати в межах цього огляду; висновки мають лишатися умовними щодо визначеної нульової моделі.

2.3 Конкретні дефекти валідності

`N1_hostages` реагує на слова чи число на кшталт «40»/«підвал»; `N3_tcc_camp` включає загальне «бусиф» і широкі «з тюрьм/из тюрьм»; `N4_cover_up` може реагувати на назву «Хартія». `N0_official` розпізнає фрази/джерела, але не позицію автора. Заперечення обробляється переважно тільки в N2 і на рівні речення. Такі правила можуть однаково спрацювати на підтримку, цитату, репортаж, питання та спростування.

У `validation_sample.py` експортований текст обрізається `text_clean[:1200]`. Для довгих дописів це може приховати контекст або висновок, тому для gold потрібно давати повний текст і джерело контексту.

`manual_labels_claude_test.csv` містить Claude-мітки. Інша LLM не є незалежним людським еталоном; узгодженість моделей не гарантує людської валідності через корельовані помилки [13].

2.4 Кількісний наслідок 40-постової перевірки

Нижче - `agreement_test_v2.csv` та точні 95% Clopper-Pearson інтервали, відновлені з TP/FP/FN. Інтервали умовні так, ніби Claude є безпомилковим gold, а приклади незалежні. Ці умови не виконані, тому цифри лише показують малий support.

Клас	Precision	95% точний інтервал	Recall	95% точний інтервал	Cohen kappa
N1	1/5 = 0,20	0,005-0,716	1/4 = 0,25	0,006-0,806	0,13
N2	2/11 = 0,18	0,023-0,518	2/5 = 0,40	0,053-0,853	0,09
N3	2/2 = 1,00	0,158-1,000	2/4 = 0,50	0,068-0,932	0,64
N4	0/2 = 0,00	0,000-0,842	0/4 = 0,00	0,000-0,602	-0,07
N0	7/9 = 0,78	0,400-0,972	7/11 = 0,64	0,308-0,891	0,60

Отже, N3 precision 1,00 є 2/2 збігами. Це не свідчення майже безпомилкового класифікатора. N4 0/2 також не доводить відсутності класу: у референсній мітці лише чотири позитивні приклади.

2.5 Межі висновків із поточних даних

Твердження	Статус	Причина
Regex знаходить текстові кандидати N1-N4/N0	Підтверджено як поведінка коду	Детерміновані шаблони
Regex встановлює, що автор підтримує claim	Не підтверджено	Немає поля stance; низькі N1/N2/N4 метрики
Панель відображає весь Telegram	Не можна стверджувати	Цільова, не ймовірнісна вибірка каналів
95,7%/88,9% - частка людей, охоплених наративом	Не можна стверджувати	Сума snapshot counters не дедуплікує людей чи повторні перегляди
Авто-С доводить проросійське джерело або контроль	Не можна стверджувати	Правило вимірює profile/domain/link cues
Текстові копії доводять державну операцію	Не можна стверджувати	Схожість є приводом перевірки, не доказом командування

3. Науковий огляд: narratives, claims, stance та автоматичне кодування

3.1 Це різні задачі вимірювання

Задача	Що вимірює	Що не можна вивести автоматично
Topic detection	Про що йдеться: мобілізація, інцидент, суд	Чи підтримує автор тезу; чи вона істинна
Claim detection	Перевірне твердження, його span і заявлене джерело	Чи воно check-worthy, чи істинне, чи автор його поділяє
Stance detection	Позицію мовця щодо конкретного claim/target	Правдивість claim або приватне переконання автора поза текстом
Framing / persuasion	Як подано причини, винних, жертв та риторичні засоби	Координацію чи державний контроль
Narrative analysis	Повторювану сюжетну інтерпретацію акторів, причин і наслідків у корпусі	Не є темою одного допису або ярликом «фейк»
Verification status	Що підтверджують доступні джерела на момент перевірки	Не можна прирівняти до stance

Hardalov et al. розглядають stance як окрему ланку misinformation analysis і відмежовують її від fact-checking та rumor verification [1]. У RumourEval 2019 stance відповіді (support, deny, query, comment) та veracity чутки були окремими мітками [5]. SemEval-2023 розвів genre, framing і persuasion techniques [3]. SemEval-2025 додав topic-specific narrative labels, entity framing і пояснення narrative [4]. Це підтримує схему `Topic -> Claim -> Stance -> Verification Status`, але як пов’язані multi-label поля, а не одна категорія на допис.

У дослідженні Telegram Willaert аналізує 2,724,187 дописів у 492 каналах і вивчає, як affordances підтримують narrative continuity [2]. Це не є доказом stance або truth окремого локального повідомлення; «наратив» доцільно агрегувати на рівні повторюваних claims/frames.

3.2 Порівняння алгоритмів і емпіричних результатів

Метод / джерело	Емпіричний результат	Межа для Social
Regex / правила	Дешево, повторювано, пояснювано; придатні як baseline і точні cue	Не вирішують цитату, сарказм, target stance і багатозначний контекст
TF-IDF word+char + LR/SVM	Недорогий контрольний baseline для малого gold	Гірше переносить нові формулювання, довгі залежності; SVM scores треба калібрувати
XLM-R / multilingual encoder	Вчить контекст і спільні UA/RU патерни	Потрібен нативний gold і leakage-aware split; помилки можуть різнитися за мовою
SetFit	Few-shot sentence transformer + classifier head; у статті конкурентний із більшим fine-tuning на ряді задач [14]	Не benchmark української/російської stance; дуже мало позитивів не дає надійності
Zero-shot NLI	Зручний cold-start baseline зіставлення тексту з гіпотезою	Чутливий до формулювання, мови і домену; не є gold
LLM annotation	Gilardi et al.: 6 183 items; GPT-3.5 у середньому випередив crowd workers приблизно на 25 pp у вибраних задачах [8]	Англомовні завдання; benchmark сам спирався на human coding; не переноситься автоматично на UA/RU іронію
LLM і supervised baselines	Mellon et al.: на 50-класовій survey класифікації best Claude few-shot мав 80,9% на novel text проти 88,6% human і 77,8% DistilRoBERTa, навченої на 576 тис. прикладів [9]	Англомовні survey responses, інший жанр
LLM проти DistilBERT	Kristensen-McLachlan et al.: на 1 000 multicoded tweets для кожної з двох бінарних задач supervised DistilBERT загалом перевершував більшість LLM налаштувань [10]	Просте англомовне завдання, однак прямий аргумент за локальну перевірку і reproducibility
GPT-4 propaganda	На 8K paragraphs якість GPT-4 падала від binary paragraph detection до span/technique; fine-tuned моделі були кращі; були труднощі в 6 мовах [7]	Propaganda techniques не дорівнюють stance щодо локального claim
LLM council / hybrid	WASSA 2026: LLM часто мали високий recall і нижчу precision; у JMBX human-LLM hybrid setup покращив weighted F1 порівняно з одиночним LLM режимом [12]	Не означає, що vote кількох LLM незалежний чи універсально кращий
Корельовані помилки LLM	Kim et al. оцінили понад 350 моделей; у одному leaderboard dataset, за умовою що обидві моделі помилялись, вони збігалися в 60% випадків [13]	Не тест української stance; демонструє, що cross-model agreement не є незалежним gold

Практичний benchmark Social: поточний regex, TF-IDF word+char + Logistic Regression / linear SVM, а далі - XLM-R або SetFit за достатньої кількості людських міток. NLI й version-pinned LLM залишити comparative baselines. Не вибирати найбільшу модель без paired test: у COLING study transfer на українську залежав від типу задачі, а результати між translated і natural test відрізнялись, що підкреслює потребу в автентичному українському наборі [15].

3.3 Роль LLM та дублікати

Емпіричні результати LLM змішані: на частині задач вони близькі до людей або кращі за crowd workers; в інших - непередбачувані між prompt/model/task і поступаються supervised baseline [8-12,28]. Тому LLM може давати окрему пропозицію з evidence span, але не заміняти людський gold. Якщо codebook coder бачить її до свого рішення, його мітка вже не є незалежною.

Mu et al. проаналізували 20 CSS datasets і встановили, що дублікати можуть створити inconsistent labels та leakage, завищуючи переносимість [16]. У Social exact/near copies треба об’єднати в duplicate family до train/test split; окремо перевіряти held-out channels, а надалі - held-out event.

SemEval-2025 Task 10 охопив Ukraine-Russia War у п’яти мовах, включно з російською; офіційна тестова таблиця показує найкращий Exact Match Ratio Narrative Classification для російської 0,56540 (DUTIR) 4; офіційна таблиця результатів. Це свідчить про складність повної ієрархічної мітки навіть у спільному benchmark; це не оцінка Social, бо жанр там онлайн-новини.

4. Narrative Classification v3 - Scientific Methodology

4.1 Таксономія та одиниця кодування

Одиниця - допис разом із доступною цитатою, forwarded source або parent-context, без якого stance не читається. В одному дописі може бути кілька claim-ів, мовців і позицій.

Поле	Значення / структура	Правило
topic	0..n тем	Предмет, не позиція і не truth
claim	0..n propositions; claim span/id; checkable/unclear	Записати конкретне твердження і джерело висловлювання
speaker/provenance	author; named source; forwarded; unknown	Цитата не є автоматично думкою автора
commitment	asserts; quotes/reports; asks; hypothetical; rejects; mixed; unclear	Кодувати лише видимий текст
stance-to-claim	supports; denies; questions; reports/no stance; mixed; unclear	Вказати target claim і evidence span
rhetorical form	sarcasm/irony; satire; loaded language; technique; none/unclear	Окремий вимір; sarcasm не є stance
verification	supported; refuted; mixed; insufficient evidence; unassessed; not checkable	Окремий датований fact-check, із джерелом
narrative/frame	narrative family; frame; actor role; causal relation	Агрегується на корпусі, версіонується
uncertainty/provenance	raw votes, confidence, adjudication, context id	Зберігати підстави та первинні мітки

4.2 Переклад старих N0-N4

Стара мітка	Рішення v3
N1 заручники	Claim family незаконного утримання; окремо stance. «40», «підвал», «медик» самі не підтверджують підтримку.
N2 смерть/катування	Окремі claims про смерть, насильство, травму, час і причинність; травма до події ≠ травма внаслідок події.
N3 «концтабір ТЦК»	Розвести literal frame, ширший claim, тему мобілізації й stance; не зливати «бусиф» із конкретним claim.
N4 приховування	Визначити актора, дію та приховуваний доказ; назва «Хартія» не є claim про приховування.
N0 офіційна версія	Перенести в source attribution + claim + stance; згадка чиновника не є нейтральною чи підтримувальною позицією автоматично.
debunk/counter-debunk	Відношення `rebuts(claim X)` і окреме ставлення до rebuttal; спростування може повторити оригінальну лексику.

4.3 Ground truth: незалежне кодування

Мінімально достатній дизайн: двоє навчених людей незалежно кодують той самий стратифікований набір; перед основною розміткою робиться невеликий пілот, уточнюється кодбук, після чого його фіксують [22,24]. Основний набір кодується сліпо до regex/ML/LLM-передбачень. Третій adjudicator розглядає розбіжності, але початкові мітки обох кодерів зберігаються. Так можна окремо оцінити людську відтворюваність і якість моделі; після adjudication лишається консенсусна мітка для навчання.

Кожен запис має зберігати: `item_id`, повний текст або контрольований доступ до нього, мову, часову позначку, канал, thread/forward context, `duplicate_family_id`, codebook version, мітку кожного кодера, span-доказ, `unclear` reason, adjudication і дату. 1 200-символьний експорт не використовувати як єдине джерело: coder мусить бачити повний зміст та релевантний parent/forward, не відкриваючи автоматичні мітки.

Метод	Перевага	Ризик	Роль у Social
Подвійна людська анотація	Дає відтворюваність між людьми на реальній задачі	Вартість; люди теж помиляються	Основний gold, принаймні на audit/test частині

Метод	Перевага	Ризик	Роль у Social
Експертна анотація	Краще розуміння кейсу, юридичної/мовної неоднозначності	Один експерт може нав'язати власну інтерпретацію; дорого	Adjudication і формулювання кодбуку, не єдина мітка
Adjudication	Розв'язує конкретні конфлікти	Якщо стерти початкові голоси, приховає неоднозначність	Третій незалежний арбітр; raw labels лишаються
LLM-assisted	Прискорює пошук кандидатів, пропонує evidence spans	Якоріння людського кодера; непрозора версійність; корельована помилка	Відокремлений пропонувальник після human gold; не показувати перед сліпою розміткою
LLM-only	Швидко і дешево на першому проході	Валідації не створює; prompt/provider drift; domain/language error	Лише слабкий label для triage, ніколи не називати ground truth
Active learning	Збільшує інформацію на одиницю ручної розмітки	Вибір за невпевненістю змінює prevalence sample; важко оцінити популяційні метрики без audit random sample	Окремий training pool; не підміняє probability audit
Стратифікований sampling	Забезпечує positives, мови, тонкі випадки	Без ваг дає зміщену поширеність	Для оцінювання: відомі inclusion probabilities; reweighting для corpus metrics

Дослідження LLM-кодування дають неоднорідні результати й залежать від task/domain: Gilardi et al. знайшли перевагу GPT-3.5 над crowdworkers на визначених задачах; Mellon et al. зафіксували відставання від людського кодування на novel responses; Kristensen-McLachlan et al. показали перевагу supervised DistilBERT над більшістю tested LLM setups у двох задачах; Hasanain et al. виявили, що GPT-4 слабшав на span/технічно дрібнішому рівні. Це не взаємовиключні висновки: саме тому Social має виміряти помилку на власному UA/RU кейсі, а не вибрати переможця з іншої мови/жанру [7-10]. Якщо до помилки людини і LLM додати кілька моделей, не можна рахувати їхні голоси як незалежні: у великому оцінюванні 350+ моделей спільні помилки були суттєво корельовані [13].

4.4 Скільки прикладів розмічати

Для простого опису частки мітки у скінченному корпусі `N=1,408`, за SRS без повернення, консервативної невідомої prevalence `p=0.5`, рівня 95% і абсолютної похибки `d` нормальне наближення з поправкою на скінченну сукупність дає:

`n0 = z²(0.975) p(1-p) / d²;`

`n = N*n0 / (N - 1 + n0).`

Одержуємо **302** пости для ±5 процентних пунктів; **152** для ±7.5 п.п.; **90** для ±10 п.п. Це планувальна точність для однієї prevalence частки, не гарантія такого ж precision/recall classifier і не доказ зовнішньої репрезентативності. Для невідомої поширеності p=0.5 максимізує дисперсію. Для фінальних малих лічильників треба звітувати Wilson або точний біноміальний інтервал, а не покладатись на Wald.

Метрики моделі мають свій знаменник. Precision оцінюється серед передбачених positives; recall — серед істинних positives. Якщо хочемо оцінити recall ±10 п.п. при очікуваному recall близько 0.8, грубе `n_pos ≈ z² p(1-p)/d²` дає ~62 незалежні gold-positive випадки; консервативний p=0.5 дає ~97. При ±5 п.п. це приблизно 246 (для p=.8) або 385 (для p=.5). Це кількість **позитивних випадків у відповідному знаменнику**, а не загальна кількість випадково вибраних постів. Рідкісний class тому потребує надвибірки кандидатів і важких негативів, або повного перегляду всіх rule positives плюс випадкового аудиту rule negatives. Тоді класифікаційні metrics оцінюють з design weights / стратифікованими оцінками; не рахують на збагаченій вибірці як на звичайній випадковій.

Практична процедура: (i) для кожного класу, мови, stance-полярності й автоматичного score утворити strata; (ii) включити всі приклади, якщо stratum дуже малий, інакше взяти відомий seeded random sample; (iii) окремо зберегти випадкову audit sample з усієї панелі; (iv) звітувати точний `n` для gold positives / predicted positives, confusion matrix і confidence interval; (v) доки рідкісний клас не має достатнього support для корисної похибки, його метрики оголошувати exploratory, з інтервалом, а не «приймати» модель на одному порозі. Критерій прийняття —

нижня межа precision/recall, потрібна для конкретного рішення, визначена через ціну false positive/negative і частоту ручної перевірки; універсального наукового `F1>0.8` тут немає.

Stratified estimator prevalence: для strata `h` із відомою часткою в corpus `W_h=N_h/N`, `pˆ=Σ_h W_h pˆ_h`. За SRS у strata без повернення оцінка дисперсії `Var(pˆ)=Σ_h W_h²(1-f_h)s_h²/n_h`, де `f_h=n_h/N_h`, а `s_h²` — вибіркова дисперсія бінарної змінної. Для чутливих малих cell counts доцільні survey/replicate-weight або exact methods; не створювати вигляд точності округленням до трьох знаків.

4.5 Алгоритми: рішення для малого UA/RU корпусу

Рекомендований порядок порівняння (однакові splits, однакова мітка й однаковий контекст):

1. `regex/rules` — фіксований baseline і high-recall candidate finder; кожен спрацьований span має бути видимий.
2. TF-IDF word + char n-grams із Logistic Regression і linear SVM — дешевий локальний контроль, інспектовані коефіцієнти/приклади; calibrate scores на train-only folds.
3. XLM-R або інший multilingually pretrained encoder — лише коли є достатньо незалежних human-labelled families; train на UA/RU окремо також як діагностика, не лише об'єднаний score.
4. SetFit як few-shot варіант: контрастивне fine-tuning sentence encoder + classifier head; праця авторів показує конкурентність на низці low-resource tasks, але не доводить ефективність для sarcastic Ukrainian Telegram [14].
5. Zero-shot NLI та version-pinned LLM — порівняльні systems: prompt/template фіксується, output зберігає span і коротку підставу, API/model/date/temperature записуються. Застосувати до всього корпусу лише після порівняння та оцінки вартості/приватності.
6. Hybrid: rules/high-recall retrieval → trained classifier → abstain/manual review на невизначених випадках. Це економить експертний час, не трактуючи threshold як правду.

Для multi-label постів кожний label має окремий binary head/правило й окремий threshold, обраний у train/validation з урахуванням precision-recall tradeoff. Stance класифікується **щодо target claim**, а не як один global label на допис. Приклад `«Поліція спростувала, що людей тримали в підвалі»`: theme=затримання, claim mentioned, author stance=reports/denies claim (контекст залежить від синтаксису), verification status — окремий fact-check. Для `«Знову “офіційна версія”, звісно»` потрібна sarcastic/unclear і ручна перевірка; слова самі по собі не дають polarity.

4.6 Оцінювання класифікатора та умови прийнятності

- **Class-wise precision, recall, F1** показують помилку кожного label; опублікувати numerator/support та CI. Небезпечно усереднити N4 із масовим N0.
- **Macro-F1** дає рівну вагу категоріям, отже корисний для rare labels; він нестабільний при малій кількості positives. **Micro-F1** агрегує рішення й може приховати провал рідкісного класу. Для мульти-label доповнити exact match / label-wise confusion; exact match суворий, але інтерпретований як «всі labels правильні».
- **MCC** збалансовує TP/TN/FP/FN для кожного binary label і має сенс при дисбалансі, але теж не замінює P/R і потребує support та CI.
- **PR-AUC** інформативніший за ROC-AUC для рідкісного класу як ranking score, але залежить від prevalence; не використовувати його без test-set prevalence.
- **Calibration**: Brier score / reliability curve, а за достатнього support log loss; перевірити чи score 0.8 відповідає приблизно 80% точності у відповідному stratum. Необов'язково калібрувати, якщо output тільки candidate rank і люди ухвалюють рішення.
- **Cohen's κ** — двоє кодерів, categorical fields; поправляє за випадковою згодою, але може стати низькою при дуже рідкісній мітці. **Krippendorff's α** допускає >2 кодерів/пропуски й явно параметризує distance (nominal для stance categories). **Gwet AC1** можна подати як доповнення, щоб перевірити чутливість до prevalence; жодна з цих метрик не вимірює істинність label.

Замість одного довільного cut-off критерій прийнятності має відповідати використанню: для автоматичного внесення claim у публічний звіт потрібний консервативний precision, нижня CI межа якого перевищує заздалегідь обрану мінімальну практичну точність; для внутрішнього candidate search можна віддати перевагу recall і ручному review. Кодування stance/confidence

має мати «unclear»/abstain. Заздалегідь вказати error-cost ratio, бажаний review load та окремі межі для UA, RU, quote/negation/sarcasm. Якщо тест не набирає достатнього support — вердикт «недостатньо даних для прийнятності», а не pass.

Зміни модулів. P0: `src/analysis/narratives.py` (розділити detection і stance; повертати evidence spans, target, ruleset version, unknown), `src/analysis/validation_sample.py` (повний текст/context, stratum/probability, blinded independent fields, duplicate family), `reports/.../validation/` (зберігати два human labels і adjudication окремо). P1: нові `src/analysis/narrative_schema.py`, `narrative_train.py`, `narrative_eval.py` лише після погодження схеми; не ховати gold у поточному автоматичному CSV. Test: unit tests на negation/quote/irony, duplicate-family grouped splits, seeded export, stable metric calculation; це критерії реалізації на наступному етапі, а не зміни, зроблені цим звітом.

5. Науковий огляд: атрибуція джерел та інформаційних операцій

5.1 Що саме приписується?

«Російський канал» може означати різні речі: оператор перебуває в Росії, канал заснований там, редакція є російською, джерело публікує проросійський контент, часто посилається на ru infrastructure, має мережевий зв'язок із відомим державним медіа, отримує державне фінансування, або керується державою. Ці твердження не взаємозамінні. Відкритий Telegram зазвичай показує контент і видимі взаємодії, а не приватного власника, фінансування, інструкції або командування.

У наукових дослідженнях computational propaganda та coordinated behavior і в практичних фреймворках основний методологічний урок — розрізняти спостережувану поведінку, координацію/автентичність, суб'єкта, мету та атрибуцію. Pacheco et al. систематизують поведінкові traces як різні сигнали, а не універсальний бот-маркер; їхні концептуальні ознаки потрібні для hypothesis generation і перевірки відносно контексту [17]. Vargas et al. показують, чому benign coordinated behavior необхідно включати як контрприклад: синхронні та схожі дії бувають органічними в разі спільного публічного стимулу [18].

5.2 Професійні методики: що є опублікованим

Методичне джерело	Опублікований підхід	Межа застосування до Social
EEAS FIMI methodology/reporting	Аналіз ланцюга/інфраструктури, інструментів та екосистеми джерел; 2025 звіт показує mapping digital infrastructure й FIMI Exposure Matrix [29,30]	Державний звіт з інституційним доступом/партнерствами; схема не означає, що відкритий допис доводить атрибуцію
NATO StratCom COE / Hybrid CoE attribution framework	Технічні, поведінкові, контекстуальні докази; окремо правова й етична оцінка, з оглядом меж відкритих джерел [31]	Застосовується до операції/дій, не дає автоматичної країни походження одного каналу
ADAC.io 2025 update	Оновлення IIO attribution framework, демонстрації Doppelgänger, LVU, Paperwall та OSINT методів [32]	Експертна методика/кейс-аналіз, не універсально відкалібрований predictive score
EU DisinfoLab CIB tree (2024)	Окремі гілки coordination, source, impact, authenticity; детектор CIB як сукупність симптомів, не миттєвий діагноз [33]	Professional method; їхні індикатори не слід трактувати як калібровану ймовірність без local validation
DFRLab “Dichotomies” codebook (2020)	Двокодерна класифікація кампаній, міжкодерна надійність, розділення content/method/attribution/intent, чітке визнання випадків без attribution [34]	Framework кодує кампанії за надійними вторинними розслідуваннями; це не алгоритм атрибуції Telegram каналів
Graphika reports	Публічні case reports реконструюють мережу та тактики з відкритих сигналів, явно спираючись на кейсні докази [36]	Не можна уявляти невідкриті внутрішні scoring SOP як опублікований стандарт
Meta CIB policy/transparency reports	Платформне визначення enforcement: coordinated efforts to manipulate public debate with fake accounts; повідомляє власні takedowns та контекст доступу платформи [35]	Платформне рішення не є незалежною універсальною дефініцією, а відсутність takedown не свідчить про відсутність CIB

Професійний звіт може мати доступ до account registration, payment data, IP/technical indicators, платформних даних або інсайдерського матеріалу, відсутніх у Social. Тому треба розмітити джерело сигналу: public-observable, platform-confirmed, documentary, third-party reported, investigator inference. Не приписувати Graphika, DFRLab, NATO або EEAS внутрішніх правил чи точних score, яких вони не оприлюднили.

Peer-reviewed дослідження каналів і diffusion дають можливість тестувати моделі на спостережених поведінкових графах, але зв'язність мережі/спільний repost сама по собі не встановлює організатора. Kireev et al. досліджують поширення пропаганди через Telegram-канали й replies; їхній 97.6% результат стосується конкретного детектора на конкретному корпусі, а не державної атрибуції чи універсальної класифікації ботів [20]. Smith et al. застосовують Bayesian inference для пошуку груп акаунтів за поведінковими характеристиками й narrative targeting; валідація охоплювала п’ять відомих CIO у чотирьох Twitter-темах. PR-AUC зросла в 76–580 разів проти naive baseline і в 1.3–4.8 раза порівняно з окремими weak flags/narratives. Це емпіричний результат для їхньої задачі/корпусу, а не готовий Social score [19].

5.3 Що виводиться з відкритих Telegram слідів

Можна безпосередньо встановити (з provenance та timestamp): який видимий текст/медіа опублікував канал; які посилання він поширив; коли це спостерігалось; видимі forward/source поля; публічну послідовність повторів; доступні profile descriptions; snapshot counters; текстову/часову/графову подібність за наперед визначеним алгоритмом. Це observations.

Можна робити **обмежену інференцію** про контентний профіль або поведінкову спорідненість, якщо вибірка, ознаки, помилка та альтернативи описані. Не можна з публічного тексту самим по собі встановити власника, фізичне місцезнаходження оператора, фінансування, приховану координацію, державне tasking, намір, bot/human identity або унікальну аудиторію. Такі твердження потребують зовнішніх первинних документів, платформних даних/підтвердження, повторюваних незалежних індикаторів, або залишаються unknown.

6. Channel Classification and Attribution Framework v2

6.1 Багатовимірна схема

Прибрати значення A/B/C/D/E/U як єдиний взаємовиключний тип. Зберегти `group_legacy` лише для відтворення попереднього звіту. В аналітичних таблицях мати такі **незалежні поля** на канал/версію часу:

Вимір	Поля / допустимі значення	Підстава і заборона висновку
Origin	`country_claim`, `basis` (self-description, registry, newsroom address, platform disclosure, unknown), validity interval	Країна мови не є origin; operator origin може бути unknown
Entity type	state media, private newsroom, public service, journalist, NGO, political actor, aggregator, anonymous channel, other/unknown	Кодувати видимого/документованого суб'єкта, а не політичний зміст
Ownership / control	owner, parent, funding, board, editor, control evidence; each `known / reported / unknown`	State control — окреме твердження з джерелом; фінансування саме по собі не завжди = редакційне керування
Content orientation	sample-level labels: pro/anti/neutral/contested on named actor/topic, mixed, insufficient	Визначати на заздалегідь вибраному корпусі та часовому вікні, із coders/reliability; не перенести на країну чи оператора
Infrastructure	domains, redirects, URL shorteners, hosting/ownership where documented, cross-platform handles, profile self-links	Link share — лише описовий сигнал; реєстраційні/technical links — документуються окремо
Network relation	forward/repost, shared URLs, temporal similarity, co-amplification, direct link	Вказувати тип edge, time window, count, expected null; network adjacency ≠ shared command
Coordination	none observed / candidate / supported / contradicted / unknown; observed behavior and test	Прив'язати висновок до названої пари/кластеру, ознак, benign controls і null model; не ототожнювати з ботом

Вимір	Поля / допустимі значення	Підстава і заборона висновку
Operational attribution	none / possible / assessed / independently corroborated / authoritative attribution / unknown	Кожен рівень має вимагати конкретного доказу й названого суб'єкта; не додавати балами без calibrated model
Evidence confidence	high/moderate/low/insufficient; separate claim-level record	Якісна оцінка якості/незалежності/специфічності доказів, не probability без калібрування
Contrary evidence	evidence against each claim, unresolved alternative explanations	Обов'язкове поле; якщо порожнє — це не доказ відсутності суперечностей
Provenance/version	source URL/archive, capture time, quote/hash, analyst, rule version, change reason	Забезпечити повторне кодування на задану дату

Channel can be “Russian-origin media”, “pro-Russian on this sample/topic”, “linked to Russian infrastructure”, “state-controlled”, and “part of a coordinated operation” as separate booleans/categorical claims. It can satisfy any subset. A Russian state-owned media outlet may be both `entity_type=state_media` and `origin=Russia`; a Ukrainian fact-checker quoting `.ru` sources may have `origin=Ukraine`, `orientation=anti-disinformation`, `infrastructure=links_to_RU_domains`, and no operational attribution.

6.2 Доказові формулювання

Публічне формулювання	Мінімально потрібна підстава	Чого недостатньо
«Канал публікує матеріали російською»	Спостережений текст у визначеному зрізі	Для країни походження — нічого
«Контент у відібраній вибірці має проросійське framing щодо X»	Наперед визначений codebook, representative sample within channel-window, independent coding, class support та disagreement	Одна цитата або мова; це твердження про контент, не контроль
«Канал посилається на російську інфраструктуру»	Перевірені URL/домен/редиректи із датою і кількістю	Сам домен, що цитується для спростування; частка outbound лінків без знаменника/контексту
«Канал російського походження»	Пряме саморозкриття, редакційна адреса/юридична особа/надійне незалежне документування оператора	Російська мова, прапор/назва, .ru, про-російська позиція
«Пов'язаний із російським державним медіа/структурою»	Підтверджений ownership, спільна редакційна/юридична особа, офіційне disclosure, чи кілька незалежних специфічних документованих зв'язків	Similar content, same hashtag, forward, спільний домен без ownership chain
«Контрольований державою»	Документи/визнання/юридична структура чи надійна незалежна атрибуція, що показує здатність і фактичне редакційне/операційне керування	Державне фінансування саме по собі, державний наратив, державний чиновник у цитаті
«Учасник координованої інформаційної операції»	Поведінкова координація, визначена з базовою частотою та контрольними organic cases, і окремі докази неавтентичності/операційного зв'язку; scope і альтернативи	Часте reposting, текстові копії, одиничний синхронний сплеск
«Операція спрямована державою РФ»	Публічна атрибуція від компетентного/незалежно обґрунтованого розслідування з evidence trail або прямі документи/технічні/організаційні зв'язки	Попередні рівні самі по собі; narrative alignment або «вигода для РФ»

Це evidence ladder для **типу твердження**, не формальна шкала ймовірності. Декілька слабких correlated cues (мова + домен + наратив) не перетворюються автоматично на один сильний доказ. Висновок має вказувати, яке твердження саме, кому воно належить, часову чинність і альтернативу.

6.3 False-positive аудит для `auto_groups.py`

Поточне правило — російські infrastructure markers у profile **або** понад 30% російських outbound domains за мінімум п'яти посиланнями — доцільно трактувати лише як `infrastructure_candidate=true` для ручного перегляду. Поріг 30% не має показаного empirical calibration; ним не можна називати весь канал групою C. Посилання можуть бути цитатами/спростуваннями, feed embeds, агрегованими новинами або короткочасним темпом події.

Для кожного candidate запустити adversarial counterexample audit: (1) українські OSINT/fact-check канали, які цитують російські джерела для перевірки; (2) українськомовні редакції з російським доменом/сервісом або старим описом; (3) російські опозиційні/незалежні канали; (4) українські канали, що поширюють проросійські тези без російського походження; (5) російський офіційний домен, що використаний лише у цитаті. Annotator бачить URL context, а не тільки host. Звітити confusion matrix для кожної окремої осі; не одну accuracy для згорнутої «C» категорії.

6.4 Двоетапне кодування та рев'ю

Stage 1 — observable profile: два дослідники незалежно заповнюють origin/type/ownership/content/infrastructure/network facts із відкритими доказами; content orientation оцінюють на випадково вибраних постах за період, не лише на матеріалах, що ілюструють підозру. Для вручну відібраного кейса відрізнити purposive evidence sample від prevalence sample.

Stage 2 — inference: інший reviewer, по можливості не той, хто збирав case, оцінює coordination/operational attribution за сформованою evidence table і альтернативними поясненнями. Один evidence item має мати `source`, `captured_at`, `specificity`, `independence_group`, `supports_claim`, `contradicts_claim`, `access_class`. Один і той самий передрукований матеріал у п'яти виданнях — один evidence lineage, не п'ять незалежних джерел.

Правила confidence: **high** — claim безпосередньо підкріплено специфічними першоджерелами або декількома незалежними доказовими лініями, альтернативи перевірено; **moderate** — кілька сумісних, але частково непрямих ліній; **low** — переважно непрямі/залежні сигнали чи мала вибірка; **insufficient** — джерела/ідентичність/час не дозволяють судити. Це операційні якісні визначення, які вимагають кодбук і подвійний аудит; не мають читатися як статистично калібрована 0.8 probability.

Зміни модулів. P0: `src/analysis/auto_groups.py` має видавати feature vector + reason codes + raw denominator, не group attribution; `config/channel_groups_auto.csv` перейменувати семантично у candidate/evidence export і версіонувати; `config/channel_groups.csv` лишити як legacy snapshot. P1: додати `config/channel_evidence.csv` з мультиосьовими claims/provenance/validity/contrary evidence і скрипт validation report; `analyze.py` групувати за явним виміром, обчислювати `unknown/ambiguous` окремо, відтворювати legacy таблиці тільки за `--legacy-groups`. Acceptance: жодна profile/domain clue не автоматично встановлює origin/stance/control; кожне опубліковане attributed aggregate має розклад за evidence status і sensitivity table.

7. Науковий огляд: похибка вимірювання та невизначеність

7.1 Різні джерела невизначеності не згортаються в один CI

1. **Annotation uncertainty:** чи пост є відповідним claim, і яка stance? Для автоматичного label оцінюється через independently coded audit set; мала тестова вибірка дає широкі інтервали.
2. **Channel-label uncertainty:** чи канал підпадає під визначений контентний/інституційний клас? Помилка каналу впливає одразу на всі його пости; одиниця не незалежна на рівні постів.
3. **Snapshot/count uncertainty:** views — лічильник у момент збору, залежить від віку поста й часу snapshot; не унікальні люди.
4. **Coverage / selection:** зібрано 241 цільовий канал і часткові платформи; відсутні дані та відбір джерел не є звичайною sampling error; великі nonprobability datasets можуть лишатися selection-biased і не дають population inference лише через обсяг [25,26].

5. **Dependence:** пости вкладені в канали, часові хвилі, duplicate families і розповсюджувальні мережі.
6. **Model specification:** вибір нульової моделі, linkage threshold, семантичного дедупу чи правила inclusion задає інший estimand.
7. **External validity:** один подієвий кейс не дає оцінити поведінку всіх подій/платформ.

Ці компоненти слід подавати окремо. Yang et al. на реальних веб/соцданих і симуляціях показали, що misclassification у data-mined variable зміщує наступні оцінки та що SIMEX/MC-SIMEX можуть коригувати деякі моделі за валідизаційною інформацією [21]. Song et al. попереджають, що людський «gold standard» у political communication часто не перевіряють за якістю; це саме ризик Claude-only reference в Social [22]. Tötsch & Hoffmann показують, як побудувати ймовірнісну невизначеність метрик з confusion matrix і наскільки малі test samples можуть робити performance оцінки нестабільними [23].

7.2 Що саме означають 95.7% та 88.9%

Для відтворення попереднього результату legacy snapshot-weighted estimand для N3 (230 дописів у повному зрізі):

```
p_C|N3 = Σ_i v_i · 1(L_i=N3_legacy) · 1(G_i=C) / Σ_i v_i · 1(L_i=N3_legacy)
```

де `v_i` — view counter у зазначений момент; `L_i` — legacy regex narrative label; `G_i` — legacy channel group. Після v3 треба публікувати різні оцінки для «claim згадано» і «автор підтримує claim», із новими знаменниками; не порівнювати їх так, наче це одна незмінна категорія. Якщо 14.13M є знаменником однакових N3 post snapshots, значення 95.7% описує частку **суми counters у відібраних N3-постах**, віднесену до group C за поточною класифікацією. Це не: share уникальних переглядачів; імовірність, що людина побачила N3; prevalence у Telegram; частка переконаних; causal influence.

У звуженій множині 81 поста/4.37M counters оцінка 88.9%. За округленими наведеними агрегатами різниця становить 6.8 п.п. Але два числа **не є статистичними bounds однієї латентної частки**: вони різняться тим, які канали/мітки включено. Лише якщо знаменники — ті самі лічильники й група C на excluded subset має той самий meaning, excluded segment приблизно 9.76M counters, з яких 9.64M (98.7%) належать C. Це арифметична декомпозиція округлених snapshot sums, що ілюструє високу вагу виключеного сегмента. Вона не виправляє канал- чи наративну помилку.

Краще звітувати паралельно:

- `p_post|N3`: кількість постів групи C серед N3-постів (не зважена post share); для v3 рахувати окремо для згадки claim та авторської підтримки;
- `p_channel`: канали C із ≥1 підтвердженим N3 post / канали у відповідній групі (із знаменником визначеним наперед);
- `p_snapshot`: сума counters за вище наведеною формулою;
- окрему таблицю individual channel contribution / top-k concentration;
- `view_counter_at` та `post_age_at_snapshot`, якщо відомі; інтерпретувати snapshot counts лише за порівнюваних capture lags або явно нормувати/стратифікувати за віком.

7.3 Вибір методів невизначеності

Метод	Корисний у Social для	Не вирішує
Confusion-matrix / misclassification correction	Оцінити post-label error з audit gold; correction для prevalence за sensitivity/specificity і відомої sampling design	Не коригує selection bias і label/channel dependency автоматично
Probabilistic classification / multiple imputation	Перенести uncertainty в агрегат, замість thresholding score у 0/1	Калібрація/conditional error усе ще потребує gold; LLM score не є probability by default
Bayesian uncertainty propagation	Спільно семплювати latent post labels і channel axes із posterior, обчислювати ratio кожним draw	Залежить від likelihood/priors; інтервал є модельним, не безприпущеневим
Cluster bootstrap	Оцінити variability, якщо ціль — superpopulation/cluster-sampling of channels і є достатньо незалежних каналів	Не робить purposive 241-канальну панель репрезентативною; пост-level IID bootstrap хибний
Multiple imputation	Утримати missing/uncertain labels у наборі та агрегувати оцінки across draws	Не є magic repair для systematically unobserved sources або неперевірених classes
Partial identification / worst-case bounds	Показати мінімум/максимум оцінки при labels/group status unknown або в заданому error envelope	Не є confidence interval; ширина може бути великою
Sensitivity grid	Показати, коли headline зміниться під альтернативними coding/group/weighting rules	Значення grid не є ймовірністю сценарію без обґрунтованої distribution
Selection/coverage model	Поправка на selection, якщо включення має відомі/оцінювані propensity та є target covariates	Невідомі пропуски й цільовий sampling mechanism не ідентифікуються лише з corpus

Для N3 частки слід уникнути naive correction лише за одним зведеним `precision/recall`: weighted ratio нелінійний, channel labels cluster-level, а тяжкі канали домінують denominator. Використати record-level gold audit, калібровані probabilities **за language/quotation/context strata**, і робити joint recomputation. Якщо вибіркова валідація не дозволяє оцінити error matrix для одного strata — показати range при plausible Se/Sp чи назвати estimand partial.

8. Measurement Uncertainty and Robustness Framework

8.1 Основний аналіз для фіксованої панелі

Для кожного допису `i` зберігати ймовірності/множину допустимих labels `q_i(L)`; для кожного каналу `c` — стан/ймовірність за кожним незалежним axis `r_c(G)`, включно з `unknown`. Доступні probabilities можуть бути calibrated ML estimates або adjudicated uncertainty labels; classifier raw confidence напряму використовувати не можна.

Кожен Monte Carlo draw `m`:

1. Якщо bootstrap-трактування виправдане, спершу семплювати **канали/кластери**, а не пости [27]; для опису вже переписаного корпусу цей крок опустити.
2. Для кожного каналу один раз draw-ити його latent origin/content/affiliation class. Цей draw спільний для всіх постів каналу.
3. Для кожного duplicate-family draw-ити узгоджений latent claim/stance за спільним text-family state; зберегти можливість, що копія адаптована/заперечена, коли є human-coded distinction.
4. Окремо draw-ити ambiguous post labels conditional on model/gold stratum, включно з `unclear`/abstain; перевіряти sensitivity щодо assumptions про correlation всередині family.
5. Обчислити `p_post`, `p_snapshot`, channel-level shares, top-5/top-10 contribution, ratio та відповідні знаменники для цього draw. Якщо denominator zero/very small, позначити draw, не підміняти його нулем.
6. Повторити, наприклад, для стійкої Monte Carlo precision; звітувати posterior median/credible interval тільки з назвою priors і model, плюс окремо audit-based/scenario result.

Це пропонує пропагувати невизначеність вимірювання через весь графік даних; алгоритмічно може бути NumPy/Pandas для простого draws або PyMC/Stan лише коли даних досить. Точність чисельної симуляції не виправляє невірний prior чи target population.

8.2 Три різні види меж

Sampling confidence interval: дозволений тільки для визначеної probability sample / sampling design щодо кінцевої сукупності (або для явно заявленої superpopulation-моделі). Для всієї вже вивантаженої цільової панелі описова частка є census statistic панелі — sampling CI не потрібен; можна мати вимірювальну невизначеність.

Model-based credible/confidence interval: posterior/SE під конкретною моделлю label error, channel dependence і priors. Назвати всі припущення та не називати це «95% шансом, що РФ керувала».

Scenario/sensitivity envelope або partial-identification bounds: мінімум/максимум після ручної зміни невідомих labels/груп за заданим правилом. Це не 95% CI і не «ймовірний діапазон»; описує межі за обмеженим набором альтернатив.

Якщо відсутні саме канали/пости систематично пов'язані з outcome і propensity невідомий, жоден bootstrap/multiple imputation на наявних рядках не відновить їх без додаткових даних/припущень. Тоді правильна відповідь — target описати як спостережений корпус і провести часткову межу лише для відомих missing classifications, а не створити псевдо-coverage estimate.

8.3 Мінімальний набір robustness tables

- Вихідна legacy група vs manual-only vs auto-included vs exclude-unknown; окремо origin, content orientation і state-affiliation axis.
- Три narrative policies: буквальна згадка, авторська підтримка, підтверджені claims only; однакові denominator definitions.
- View counters: unweighted post count, raw snapshot sums, per-channel capped/contribution scenarios (caps як diagnostics, не виправлена reach), age-stratified snapshot; leave-one-channel-out / top-1,5,10 removed.
- Coverage: narrow (confirmed post texts), broader candidate search, source-sensitivity inclusion; не вважати missing Instagram/TikTok/Threads механічно нульовими.
- Duplicate treatment: exact-only, near-copy-family, exclude quotations; group split diagnostics.
- Uncertainty: calibrated posterior draws; frequentist design-based estimates де доступні; partial identification for unknown; окремо “no general-population interval.”
- Коментарі: окремі міри activity/coordination та nonhuman-likelihood. Bot label не входить у channel attribution і не означає state affiliation.

Для погляду на чутливість ваг: Kish effective sample size $n_{eff}=(\Sigma w_i)^2/\Sigma w_i^2$ можна дати як концентраційну діагностику (на рівні визначених незалежних units, не рядків); також Lorenz/top-k share для channel weights. Високий n_{eff} не доводить representative sample, а низький покаже, що кілька великих channel counters визначають агрегат.

Дедуплікація аудиторій. Не підсумовувати channel subscribers/views як reach. Без cross-channel person-level exposure можна розрахувати only bounds у спрощених умовах: union не менший за максимальне одиничне охоплення та не більший за суму, capped числом потенційної аудиторії за відомих спільних одиниць; реальні views counters можуть мати повтори і не тотожні reach, тож навіть ці межі часто малоінформативні. Краще термін: «сума зафіксованих лічильників переглядів на дату збору».

Зміни модулів. P0: `src/analysis/analyze.py` доповнити точними estimand names/denominators/snapshot metadata і channel-contribution; не перейменовувати показник на reach. P1: новий `src/analysis/uncertainty.py` для metric draws, cluster/channel-level group uncertainty, partial bounds та sensitivity config; `reports/.../signals.json`/CSV передавати sample inclusion probability і classifier audit strata. P2: `src/analysis/telegram_network_dynamics.py` robustness для duplicate communities/null models (існуючі тестові ядра зберегти; не переносити false discovery rationale між різними гіпотезами). Validation: hand-calculated synthetic fixtures із відомими label/group errors; перевірка, що всі пости одного каналу користуються одним group draw; ratio recalc по кожному draw; test absent denominator; render таблиць із припущеннями та застереженням про selection.

9. Експериментальні протоколи

Нижче — **фактично специфіковані експерименти**, що операціоналізують знайдені недоліки. Успіх визначається не одним magic number, а валідованими класовими межами, наперед заданою практичною вартістю помилок і стабільністю ключового estimand.

E1. Незалежна перевірка конструкта й кодбуку

- **Гіпотеза:** щонайменше частина regex positives є тематичними згадками без підтримки claim; окремі stance поля знижують false-positive narrative counts.
- **Дані:** усі 1,408 релевантних дописів або probability/stratified audit за формулам §4.4; strata за N1-N4/N0 predicted label, UA/RU, цитатою/перепостом, negation, sarcasm/irony cue, high-view weight. Не скорочувати контекст.
- **Контроль:** поточний regex output, прихований від двох кодерів; окрема ручна sample з regex-negative posts, щоб оцінити recall.
- **Метод:** два незалежні human coders; третій adjudicator; coded fields topic, claim span, speaker/provenance, commitment, target stance, rhetorical form, verification available. LLM labels тільки після human passes.
- **Метрики/статистика:** per-field confusion; class precision/recall/specificity, macro-F1/MCC і exact intervals; α (nominal) та κ, plus raw agreement; weighted prevalence estimates за selection probabilities; per-language/quote subsets.
- **Критерій:** здатність сформувати незалежні мітки і чисельні CI для цільової помилки; класи із support нижче заданої precision — лишити candidate only. Публічна claim-positive категорія приймається тільки якщо нижня межа precision задовольняє наперед specified reporting cost; stance categories із нерозв'язною міжлюдською неоднозначністю залишаються mixed/unclear.
- **Негативний результат:** якщо двоє людей регулярно розходяться після codebook, проблема спершу в невизначеному конструкті/контексті, а не в тому, що слід обрати потужнішу модель; звузити claim definition або звітувати неоднозначність.

E2. Порівняння правил, класичних та multilingual моделей

- **Гіпотеза:** локально supervised classifier або hybrid із abstention може перевищити поточний regex на окремих класах; це слід встановити, не припускаючи переможця.
- **Дані:** E1 human gold; exact/near-duplicate `duplicate_family_id`, канали, event windows, мовні/context tags.
- **Контроль:** поточні regex; TF-IDF word+char + LR/SVM; XLM-R multilingual; SetFit; zero-shot NLI; pinned LLM. Для кожної системи зберегти model/prompt/dependency versions і threshold.
- **Split:** group split за duplicate family; nested grouped CV для вибору/налаштування; додатковий `held-out channel` split. Якщо корпус одного інциденту не дозволяє достатньо окремих каналів — зазначити; не робити пост-level random split із копіями в обох частинах. External event test потрібен для загальної переносимості, але не входить у вже описані корпусні метрики.
- **Метрики:** class-wise P/R/F1, macro/micro F1, MCC, PR-AUC, calibration, false positive review load, abstention coverage-risk; UA та RU, quote/negation/sarcasm breakdown. Оцінювати paired difference на однакових test cases із family-level bootstrap/paired resampling, не independent post bootstrap.
- **Критерій:** обрати найпростішу модель, що на test тримає вимоги конкретного застосування і не погіршує critical subgroup/error-cost; якщо складніша модель має overlapping wide CIs або перевага лише на leaked random split — не приймати її.
- **Негативний результат:** якщо модель не перевищує rules чи human-review workflow, rules лишаються candidate retrieval; чесно зберегти результат, не переозначати taxonomy для поліпшення score.

E3. Channel-axis audit і false positives

- **Гіпотеза:** авто-C за profile/domain markers частково змішує infrastructure cue з origin/content affiliation і дає false positives серед українських OSINT/fact-check каналів.
- **Дані:** 241 панель. Два кодери перевіряють базові публічні поля та evidence records для всіх 87 старих C (26 manual, 61 auto), щоб точно розкласти auto/manual; далі manual strata усіх інших

legacy groups, включно з adversarial negative controls. Усього каналів лише 241, тому census спостережуваних attributes кращий за довільний невеликий відбір. Для content orientation — окрема стратифікована random sample постів кожного релевантного каналу з заздалегідь визначеною похибкою §4.4; якщо ресурс не дозволяє, звітувати channel-level `insufficient`, не екстраполювати з 1–2 прикладів.

- **Контроль:** cases: verified state outlets/entities where documented; negatives: Ukrainian monitoring/fact-check sources linking RU domains; Russian-language Ukrainian outlets; Russian anti-war/opposition; pro-Russian Ukrainian content with no known Russian link; benign news event co-sharing. Use only sources with a documented basis, not “gold by intuition.”
- **Метод:** independent claim-by-claim evidence review; direct URLs + archived snapshots; 2 coders; adjudication; compare old C with independent evidence axes.
- **Метрики:** each axis precision/recall against source-supported reference; agreement; false-positive table and error explanation; change matrix of legacy C labels; stability with and without weak cues; leave one evidence category out.
- **Критерій:** automated rule may only return cue/candidate, never attributed origin/state control. If human-review errors remain substantial or source evidence cannot be verified, publish `unknown` or narrower wording.
- **Негативний результат:** if not enough positive documented state/ownership examples are in this case, no claim of sensitivity or estimated CIB/attribution accuracy; framework is a case coding schema, not classifier.

E4. Propagation of joint post and channel classification error

- **Гіпотеза:** the 95.7% N3 counter share changes materially under plausible post/whole-channel classification uncertainty, especially because a small number of high-weight channels dominate.
- **Дані:** current N3 post list, per-post counts/capture timestamps, post audit confusion/stratum labels from E1, per-channel evidence and group uncertainty from E3.
- **Control:** exact deterministic recomputation for current legacy labels; synthetic toy table with known errors and known channel cluster labels to verify code.
- **Method:** fixed-panel description + joint Monte Carlo draws; same group label draw reused for all posts of channel; duplicate-family dependence scenarios; partial bounds for unresolved labels; channel leave-one-out/top-k.
- **Metrics:** distribution of `p_post`, `p_snapshot`, channel concentration, numerator/denominator in every scenario; sensitivity interval and posterior interval separately; Kish ESS and top-k contributions.
- **Критерій:** headline becomes “robust” only if it preserves direction/magnitude under predeclared plausible coding and concentration assumptions; if the interval is broad or the conclusion flips, report the scenario range instead. No universal robustness width.
- **Негативний результат:** high uncertainty does not imply no phenomenon; it limits precision of claim. The report should show exactly which uncertain channels/posts drive it.

E5. Null-model specificity for coordination flags

- **Гіпотеза:** detector based on text/time similarity may flag ordinary synchronized reporting after a common event, unless null/control data model shared public stimuli.
- **Дані:** current comment/post candidate clusters; matched benign news bursts with comparable platform, language, size, duration, and source diversity; known postmortem campaigns only where independent attribution exists. Avoid using the suspected case as both discovery and only evaluation set.
- **Контроль:** existing permutation null model remains baseline; additional controls preserve event-time windows, account/channel activity rates, common-source exposure, and text-template base rates as far as available. Use a holdout for detector thresholds.
- **Метод:** apply existing detector without retuning to each control; pre-register which features and test family are evaluated; compare cluster statistics to event-conditioned null and organic controls. Maintain current Holm correction for its current family; any added hypotheses define a new family.
- **Metrics:** false flags per event/control, precision only where ground truth is independently known, cluster-level Jaccard agreement across windows/thresholds, effect distributions under null, per-feature stability. Do not label coordinated accounts as bots by this test.

- **Критерій:** if common-event controls produce comparable flags, downgrade detector output to “behavioral similarity/candidate coordination”; stronger claim needs evidence beyond content timing.
- **Негативний результат:** no detection under current resolution does not establish absence of coordination, especially on incomplete platform data.

E6. View-snapshot comparability and concentration

- **Гіпотеза:** raw view-sum comparison is strongly affected by post age and top channels.
- **Дані:** post `views`, exact collection time, post time, channel, first/second snapshots if retained.
- **Контроль:** current raw sum; equal-age/age-stratified subset; post-count and per-channel capped diagnostics; leave-one/top-k out.
- **Metrics:** time-lag distribution, within-channel growth if repeat snapshot exists, snapshot sum concentration, post-level and channel-level ratio. Do not claim unique users.
- **Критерій:** call a cross-group comparison descriptive snapshot only unless all capture lags and definitions are comparable; use historical cumulative growth only if repeated longitudinal measures exist.
- **Негативний результат:** if timestamps are not recorded or age lags vary, retain raw aggregate as one-time counter sum and avoid “viral/reach” conclusion.

10. Implementation Roadmap for Social

P0 — виправити ризики, що безпосередньо змінюють головний висновок

Завдання	Модулі	Технічна зміна	Перевірка/умова завершення
Розділити claim mention і author stance	`src/analysis/narratives.py`; schema file	multi-field output, target claim, evidence span, quoted source, negation/irony/unclear, versioned rules; legacy labels preserved for reproduction	Golden examples for support/quote/debunk/query/sarcasm; every label traceable to span; no auto inference of truth
Ground truth без Claude-only reference	`src/analysis/validation_sample.py`; `reports/.../validation/`	dual blinded human annotation, full text/context, two raw labels, adjudication, inclusion probability, language/context/duplicate-family fields	Inter-coder table and supports/CI generated from independent human labels; Claude labels remain separate
Перевірити rare labels за sampling design	`src/analysis/validation_sample.py`, new eval module	Stratified sample with known inclusion probabilities; include random model-negative sample; estimates weighted back to fixed corpus	Documented N_h, n_h, weight formula; exact/wilson intervals; no false precision for small support
Перекваліфікувати auto-C output	`src/analysis/auto_groups.py`; `config/channel_groups_auto.csv`	Feature flags and evidence reasons, not Russian/pro-Russian/state label; retain old output under legacy mode	Test that `.ru`, language, quoted sources alone cannot set origin/control; denominator logged

P1 — наукова перевірність і перенесення невизначеності

Завдання	Модулі	Зміна	Acceptance
Versioned evidence-axis records for channels	New `config/channel_evidence.csv` or structured JSONL; `auto_groups.py`	origin/type/orientation/infrastructure/network/ownership/attribution, provenance and contrary evidence	Two reviewers can reproduce each claim from stored source/capture
Classifier benchmark	New `src/analysis/narrative_train.py`, `narrative_eval.py`	sklearn TF-IDF LR/SVM baseline first; transformer/SetFit optional extras; model registry/config lock	duplicate-family grouped split, channel held-out eval, class/language tables, calibrations, cost/threshold report
Joint uncertainty	New `src/analysis/uncertainty.py`, `analyze.py`	record probabilities/uncertain states, channel-level shared draws, fixed-panel, bounds/sensitivity	synthetic fixtures prove ratio and dependence behavior; output labels CI vs model interval vs scenario envelope
Snapshot estimands and concentration	`src/analysis/analyze.py`	explicit `counter_sum_at_cutoff`, `p_post`, `p_snapshot`, channel contributions, age lag metadata	PDF/CSV captions never call view sum reach; every percentage has numerator/denominator and snapshot date
Duplicate leakage prevention	existing dedup pipeline; validation/split module	exact + MinHash/near-copy families built before split; context-aware variants; group all family copies	test asserts no family crosses train/dev/test; report family count and threshold
Reviewer-accessible data package	report generation/docs, existing manifest/checksum functionality	publish schema, codebook, versions, synthetic fixtures and lawfully shareable/deidentified data	command and checksum reproduce aggregate tables; access limits and deletions documented

P2 — додаткове посилення

- Cross-event benchmark to estimate transportability; one event is one case, not a campaign-class training dataset.
- Multilingual model-specific benchmark on native Ukrainian/Russian posts; translation-only tests do not stand in for natural speech [15].
- Optional Bayesian model if posterior uncertainty is a report requirement and enough audit evidence exists; otherwise design-based confusion intervals + clear bounds are easier to defend.
- Compare several predeclared event-conditioned null models for existing coordination analysis; preserve existing permutations and Holm code unless review finds a specific defect.
- A second snapshot collection wave, if platform/service terms permit, for growth rates and view-age sensitivity. This should not be backfilled by dividing current totals by post age as if growth were linear.

Dependencies (minimal): pandas/numpy/scikit-learn for weighting, metrics and baseline; scipy or statsmodels for intervals/tests; `transformers`/`torch` or `sentence-transformers`/SetFit only behind optional dependency group after the classic baseline. PyMC/Stan is optional, not required to resolve current P0. Pin versions, seed splits, freeze prompts and save model hashes. Manual labels and evidence records are the primary added cost; larger GPUs do not replace them.

11. Publication Readiness

Current judgment: the analysis is a useful exploratory computational OSINT case study, but not ready to present the N3 share, automated narrative labels, or C group as fully validated population estimates or source attribution. The primary blockers are independent label validation, unit/construct separation, channel evidence axes, uncertainty propagation through high-weight channels, and the purposive-panel scope. These are fixable methodological issues; they do not erase the descriptive observations.

For a peer-reviewed submission, the most material additions are: (1) human reliability and classifier error by class/UA/RU/quote context; (2) data and split lineage showing no duplicate-family leakage; (3) channel evidence appendix with direct provenance, contrary evidence, and explicit unknowns; (4) fixed-panel estimands and joint post/channel sensitivity; (5) benign control evaluation for coordination flags; (6) reproducible scripts/config/aggregate outputs and documented platform data constraints. If raw posts cannot be shared lawfully or ethically, provide a reproducible pipeline over a legally accessible/mocked sample, aggregate checksums, schema, redacted examples, and explain exact access limits. Do not promise exact external replication from unavailable private platform records.

Appropriate article framing: **“An exploratory digital-trace case study of how narrative, channel-classification and measurement assumptions shape inferred cross-platform information diffusion.”** Avoid claiming representative public opinion, unique reach, bot counts, state command, causal influence, or proof that an assertion is false unless the relevant measurement/primary-source evidence actually exists.

12. Верифіковані джерела

Рецензовані публікації та shared tasks

1. Hardalov, M., Arora, A., Nakov, P., & Augenstein, I. (2022). “A Survey on Stance Detection for Mis- and Disinformation Identification.” Findings of NAACL 2022, 1259–1277. DOI 10.18653/v1/2022.findings-naacl.94. Огляд постановок stance та їх зв'язку з misinformation, rumour і verification; не benchmark саме українських постів.
2. Willaert, T. (2023). “A computational analysis of Telegram’s narrative affordances.” PLOS ONE, 18(11), e0293508. DOI 10.1371/journal.pone.0293508. Аналіз 2,724,187 повідомлень у 492 каналах; narrative continuity / platform affordances, а не твердження про truth чи author stance кожного поста.
3. Piskorski, J., Stefanovitch, N., Da San Martino, G., & Nakov, P. (2023). “SemEval-2023 Task 3: Detecting the Category, the Framing, and the Persuasion Techniques in Online News in a Multi-lingual Setup.” SemEval 2023, 2343–2361. DOI 10.18653/v1/2023.semeval-1.317. Дев'ять мов, окремі genre/frame/technique tasks; онлайн-новини не Telegram comments.
4. Piskorski, J. et al. (2025). “SemEval 2025 Task 10: Multilingual Characterization and Extraction of Narratives from Online News.” SemEval 2025, 2610–2643. ACL Anthology 2025.semeval-1.331. П'ять мов включно з російською; hierarchical narrative classification, entity framing та evidence/extraction. Число 0,56540 для найкращого російськомовного Narrative Classification наведено окремо за офіційною тестовою таблицею; цей benchmark не переноситься безпосередньо на Social.
5. Gorrell, G. et al. (2019). “SemEval-2019 Task 7: RumourEval, Determining Rumour Veracity and Support for Rumours.” SemEval 2019, 845–854. DOI 10.18653/v1/S19-2147. Окремі stance та rumour veracity labels у conversation context.
6. Abu Farha, I., Oprea, S. V., Wilson, S., & Magdy, W. (2022). “SemEval-2022 Task 6: iSarcasmEval, Intended Sarcasm Detection in English and Arabic.” SemEval 2022, 802–814. DOI 10.18653/v1/2022.semeval-1.111. Авторська self-label для сарказму зменшує частину distant-label проблем, але це не український корпус.
7. Hasanain, M., Ahmad, F., & Alam, F. (2024). “Can GPT-4 Identify Propaganda? Annotation and Detection of Propaganda Spans in News Articles.” LREC-COLING 2024, 2724–2744. ACL Anthology 2024.lrec-main.244. ArPro: 8K paragraphs, 23 techniques; GPT-4 погіршився на fine-grained span/technique і мав труднощі на шести мовах.
8. Gilardi, F., Alizadeh, M., & Kubli, M. (2023). “ChatGPT outperforms crowd workers for text-annotation tasks.” PNAS, 120(30), e2305016120. DOI 10.1073/pnas.2305016120. 6,183 text items; GPT-3.5 випередив MTurk на ~25 pp average в чотирьох конкретних наборах; benchmark labels не є незалежною істиною і завдання не UA Telegram.
9. Mellon, J. et al. (2024). “Do AIs know what the most important issue is? Using language models to code open-text social survey responses at scale.” Research & Politics (2024). DOI 10.1177/20531680241231468. Claude-1.3 80.9% на novel responses проти human 88.6%, DistilRoBERTa trained on 576k 77.8%. Це інший домен/50-class survey task.
10. Kristensen-McLachlan, R. D., Canavan, M., Kárdos, M., Jacobsen, M., & Aarøe, L. (2025). “Are chatbots reliable text annotators? Sometimes.” PNAS Nexus, 4(4), pgaf069. DOI 10.1093/pnasnexus/pgaf069. На двох бінарних задачах US-news tweets DistilBERT загалом найстабільніше перевершував LLM; обмеження — англійська й простіша двокласова постановка.
11. Alizadeh, M. et al. (2025; online 2024). “Open-source LLMs for text annotation: a practical guide for model setting and fine-tuning.” Journal of Computational Social Science, 8(1), 17. DOI 10.1007/s42001-024-00345-9. Fine-tuning open-source LLM підвищував якість у кількох політичних text-label tasks; це не доказ переваги над простішими моделями на Social.

12. Sharma, V., Jain, S., Shokri, M. M., Levitan, S. I., & Filatova, E. (2026). “Council of LLMs: Evaluating Capability of Large Language Models to Annotate Propaganda.” WASSA 2026, 1–12. DOI 10.18653/v1/2026.wassa-1.1. На PTC news/JMBX social posts LLM схильні до високого recall/нижчого precision, часто over-predict; у hybrid порівняннях на JMBX human-LLM setup покращив weighted F1 відносно solo LLM. Датасети/пропаганда не еквівалентні локальному claim stance.

13. Kim, E. M., Garg, A., Peng, K., & Garg, N. (2025). “Correlated Errors in Large Language Models.” ICML 2025, PMLR 267, 30038–30066. PMLR proceedings. Оцінено 350+ LLMs; на одному leaderboard dataset, серед пар, де обидві моделі помилялися, помилки збігалися 60% часу. Не український stance task, але демонструє, чому LLM majority vote не незалежний gold.

14. Tunstall, L. et al. (2022). “Efficient Few-Shot Learning Without Prompts.” NeurIPS 2022 Workshop on Efficient Natural Language and Speech Processing; arXiv 2209.11055. Вводить SetFit; мала кількість labels може бути корисною, але результати залежать від задачі, encoder і positive support.

15. Dementieva, D., Khylenko, V., & Groh, G. (2025). “Cross-lingual Text Classification Transfer: The Case of Ukrainian.” COLING 2025, 1451–1464. ACL Anthology 2025.coling-main.97. На трьох classification/NLI задачах демонструє різні результати transfer; для NLI є падіння на natural test і автори підкреслюють потребу native Ukrainian data.

16. Mu, Y., Jin, M., Song, X., & Aletras, N. (2024). “Enhancing Data Quality through Simple De-duplication: Navigating Responsible Computational Social Science Research.” EMNLP 2024, 12477–12492. DOI 10.18653/v1/2024.emnlp-main.694. Аудит 20 CSS datasets: duplicate/near-duplicate samples створюють label inconsistency і train/test leakage, завищуючи apparent transfer/performance.

17. Pacheco, D. et al. (2021). “Uncovering Coordinated Networks on Social Media: Methods and Case Studies.” ICWSM 2021, 15(1), 455–466. DOI 10.1609/icwsm.v15i1.18075. Unsupervised coordination networks із behavioral traces у п'яти case studies; coordination сигнал не ідентифікує автоматично intent/state.

18. Vargas, L., Emami, P., & Traynor, P. (2020). “On the Detection of Disinformation Campaign Activity with Network Analysis.” ACM CCSW 2020. DOI 10.1145/3411495.3421363. F1 0.98 у known campaign activity, 0.71 на out-of-distribution task з ростом false positives; важливе нагадування про external/generalization control.

19. Smith, D. H., Ehrett, C., & Warren, P. (2025). “Unsupervised detection of coordinated information operations in the wild.” EPJ Data Science, 14, 26. DOI 10.1140/epjds/s13688-025-00544-y. Bayesian model combines behavioral and narrative indicators; posterior depends on model/prior and does not establish operator identity.

20. Kireev, K., Mykhno, Y., Troncoso, C., & Overdorf, R. (2025). “Characterizing and Detecting Propaganda-Spreading Accounts on Telegram.” USENIX Security 2025, 161–180. USENIX paper. Dataset >17M Telegram messages/comments; their study-specific moderation-oriented account detector reported 97.6% detection, 11.6 pp higher than human moderators after one message. It detects studied propaganda-spreading users, not Russian state control or general bot-ness.

21. Yang, M., Adomavicius, G., Burtch, G., & Ren, Y. (2018). “Mind the Gap: Accounting for Measurement Error and Misclassification in Variables Generated via Data Mining.” Information Systems Research, 29(1), 4–24. DOI 10.1287/isre.2017.0727. Simulations and real online datasets; SIMEX/MC-SIMEX addressed downstream estimation under specified measurement error.

22. Song, H. et al. (2020). “In validation we trust? Imperfect Gold Standards and the Validation of Automated Content Analysis.” Political Communication, 37(4), 550–572. DOI 10.1080/10584609.2020.1723752. Argues and demonstrates that manual reference labels themselves need systematic quality assurance.

23. Tötsch, N., & Hoffmann, D. (2021). “Classifier uncertainty: evidence, potential impact, and probabilistic treatment.” PeerJ Computer Science, 7, e398. DOI 10.7717/peerj-cs.398. Bayesian confusion-matrix model quantifies metric uncertainty and sample-size needs; can be used from validation counts, subject to its data model.

24. He, Z., & Schonlau, M. (2020). “Automatic Coding of Open-ended Questions into Multiple Classes: Whether and How to Use Double Coded Data.” Survey Research Methods, 14(3), 267–287. DOI 10.18148/srm/2020.v14i3.7639. Simulation and real data find double-coded training data with expert resolution can yield the best classification performance in their studied survey setting.

25. Andridge, R. R. et al. (2019). “Indices of non-ignorable selection bias for proportions estimated from non-probability samples.” Journal of the Royal Statistical Society: Series C, 68(5), 1465–1483. DOI 10.1111/rssc.12371. Simulation study; explicit selection-bias measures for descriptive proportions, relevant to why a large purposive panel does not imply population inference.

26. Meng, X.-L. (2018). “Statistical paradises and paradoxes in big data (I): Law of large populations, big data paradox, and the 2016 US presidential election.” Annals of Applied Statistics, 12(2), 685–726. DOI 10.1214/18-AOAS1161SF. Large nonprobability datasets can remain biased; size alone does not eliminate selection error.

27. MacKinnon, J. G., Nielsen, M. Ø., & Webb, M. D. (2023). “Cluster-robust inference: A guide to empirical practice.” Journal of Econometrics, 232(2), 272–299. DOI 10.1016/j.jeconom.2022.04.001. Inference unit with clustered errors is the cluster; few/unrepresentative clusters limit reliability, so channel bootstrap has explicit assumptions.

28. Alizadeh, M. et al. (2023). “Open-Source Large Language Models Outperform Crowd Workers and Approach ChatGPT in Text-Annotation Tasks.” arXiv preprint 2307.02179. This preprint is earlier work related to their later journal article [11]; it should not be counted as an independent replication.

Професійні методики та політики (не peer-reviewed)

29. EEAS (2025). 3rd EEAS Report on Foreign Information Manipulation and Interference Threats. Official report page / PDF. Публічний опис FIMI methodology та FIMI Exposure Matrix; державна аналітична практика, не peer-reviewed classifier validation.

30. EEAS (2026). 4th EEAS Annual Report on FIMI Threats: Dismantling the FIMI House of Cards. Official report page. Official operational framework drawing on FIMI response framework/toolbox; institutionally produced, not a calibrated model for open Telegram samples.

31. Palmertz, B., Isaksson, E., & Pamment, J. (2022). A Framework for Attribution of Information Influence Operations. NATO StratCom COE / Hybrid CoE. Official PDF. Separates technical, behavioral and contextual evidence and legal/ethical assessment; explicitly discusses data access limits.

32. Palmertz, B., Isaksson, E., & Pamment, J. (2025). A Framework for Attribution of Information Influence Operations: Updated version. ADAC.io. Project publication. Applied case studies; expert framework, not externally calibrated probability score.

33. Romero Vicente, A. (2024). Coordinated Inauthentic Behaviour Detection Tree. EU DisinfoLab / veraAI. Publication and PDF. Coordination, authenticity, source, and impact are separate branches; practitioner framework rather than independent probabilistic validation.

34. Brooking, E. T., Kann, A., & Rizzuto, M. (2020). Dichotomies of Disinformation: Project Overview & Codebook. DFRLab/Atlantic Council. Public codebook. Campaign-level codebook with two-coder reliability and attribution confidence; examples selected from known, reliable case reports.

35. Meta. Coordinated Inauthentic Behavior Policy / transparency reports. Policy. Platform enforcement definition, not universal scientific taxonomy.

36. Graphika. (2020). Secondary Infektion: An Operation Spanning Years, Continents, and Languages. Report. Public case study; illustrates a documentary/technical trail approach, not a reusable per-channel language heuristic.

37. EU DisinfoLab (2025). Visual assessment of CIB in disinformation campaigns. Publication. Applies 50 indicators to three cases; explicitly practitioner visual scoring and not a Social-calibrated probability.

Методичне тлумачення літератури

Ця бібліографія не є систематичним метааналізом: вона є targeted review of empirical work, shared tasks, methodological papers, and public attribution guidance directly bearing on the three failures in Social. Публікації різняться за мовою, жанром, platform access, ground truth definition, prevalence і cost. Тому згадані score/результати — не порівнювана таблиця «який алгоритм найкращий». Їхнє коректне застосування — сформувати локальні baseline-и й саме такі контрольні експерименти, що відтворюють українсько-/російськомовний короткий messaging context.

Висновок

Найбільш захищуваний науковий шлях для Social — не назвати Claude/regex/LLM «правильним», а спочатку визначити, що саме рахується: тема, конкретне твердження, позиція мовця, чи підтвердженість твердження; далі перевірити це незалежною людською розміткою, а вже потім порівняти прості та складні моделі на дедуплікованих і group-held-out splits. Джерела мають бути класифіковані за незалежними осями з provenance і невідомим станом, а не єдиним політичним bucket. Для кожного headline агрегату потрібно окремо показати частку постів, channel contribution і snapshot-counter share, поширити classification uncertainty на обидва рівні та не екстраполювати цільову панель на всю платформу.

Ці рекомендації дозволять встановлювати, наскільки спостережені патерни стійкі до помилок вимірювання. Вони самі по собі не доводять, що конкретна інформаційна хвиля була державною операцією, скільки унікальних людей її побачило, чи змінила вона переконання користувачів, або чи були коментарі автоматизованими. Такі твердження вимагають окремих, відповідних даних і evidence chains.