Autonomous Social Conflict and Incident Reconstruction — Scientific Methods and System Architecture, 2026

Науково-технічний огляд методів для проєкту Social | Дата зрізу: 7 листопада 2026 року

Зміст

1. Executive Summary
2. Automated Event Reconstruction
3. Temporal and Entity Reasoning
4. Evidence Verification and Provenance
5. Claim–Evidence–Provenance Graph Framework
6. Social Conflict Analysis
7. Multimodal Evidence
8. Autonomous AI Analysis
9. Reliability and Uncertainty
10. Experimental Validation
11. Proposed Architecture for Social
12. Data Models and Interfaces
13. Implementation Priorities
14. Scientific References

Доказова рамка огляду

Огляд поєднує експериментальні NLP та multimodal papers, evaluation shared tasks, стандарти й операційні методології. Результати benchmark-ів обмежені їхніми мовами, жанрами, датами та метриками. Практичні рекомендації відділено від експериментально показаних результатів. Відомості про Social спираються на read-only огляд checkout, зафіксований у розділі 11. Мета — автономна обробка з abstention і відтворюваністю.

1. Executive Summary

Social уже збирає матеріали, архівує джерела, нормалізує дописи, аналізує час, тексти, мережі та мультимедійні збіги. Для реконструкції самого інциденту треба пов'язати кожне повідомлення з конкретним твердженням, спостереженням або свідченням; з'ясувати походження цієї інформації; створити версійовану часову лінію; зберегти суперечності та прогалини; формувати звіт лише з локалізованих доказів.

Наукові результати не підтримують обіцянку, що автономна LLM сама встановить події з відкритого вебу з високою надійністю. У AVeriTeC 2024 переможець мав 63% за спільною метрикою verdict плюс якості доказів. У виданні 2025 після зміни корпусу й метрики найкращий результат був 0,3317 за новою спільною метрикою. Ці значення не можна прямо порівнювати, і жодне з них не є просто відсотком істинних відповідей. У публікації 2025 автори вказують, що попередня метрика доказів мала слабкий зв'язок із людською оцінкою. ALCE показує, що навіть найкращі оцінені системи часто не дають повної підтримки всім згенерованим реченням. Отже, автономність треба будувати як низку вузьких, перевірюваних операцій і формальних правил відмови від висновку.

Рекомендована система складається з незмінного evidence ledger та версійованої реконструкції. Ledger зберігає первинні файли, захоплення сторінок, хеші, passage locators, витягнуті твердження, цитати, source lineage, суперечності та історію оцінок. Реконструкція є відтворюваною проєкцією цього журналу у події, часову шкалу, статуси тверджень і звіт. Кожна версія має cutoff, використані докази, конфігурацію правил і моделей та відмінності від попередньої.

Кількість повторів не дорівнює незалежному підтвердженню. Вісім сторінок, що переповідають слова одного очевидця, — це один корінь свідчення і вісім похідних публікацій. Час події, час публікації, запису медіа, отримання та аналізу зберігаються окремо. Послідовність у часі не доводить причинність. Відео може показати видиму дію, але окремо не встановлює дату, місце, особу, причину, юридичну оцінку чи контекст до початку фрагмента.

Практичний вибір для незалежного дослідника: Python та SQLite/JSONL як локальне сховище з append-only версіями; детерміновані перевірки часу, посилань і схеми; повнотекстовий пошук плюс multilingual embeddings для пошуку кандидатів; ML/LLM для структурованого вилучення цитованих span-ів і відношень; обмежений синтез висновків із джерельними ID; механічні citation/schema/time gates до створення документа. LLM не затверджує власний висновок, а голосування кількох моделей не стає незалежним доказом.

Реалістично автоматизуються збір, пошук, витяг полів, дедуплікація, candidate matching, виявлення конфліктів, інтервальна хронологія, облік джерельної залежності, повторний розрахунок і складання доказово обмеженого звіту. Відкриті цифрові сліди самі по собі не дозволяють достовірно відновити приховані мотиви, повну кількість учасників, усі незафіксовані дії, причинний вплив на поведінку або державне керування інформаційним поширенням. Для таких питань системний результат має бути «неможливо визначити за доступними матеріалами».

2. Automated Event Reconstruction

1. Що саме можна реконструювати

Найбільш придатна для Social архітектура поєднує document-level information extraction, обережне cross-document resolution і формальний часовий граф. Вона реконструює не безпосередній «стан світу», а версіонований набір тверджень про події з окремою оцінкою доказів. Вихідний допис, факт його публікації, описана в ньому дія і висновок аналітичної системи мають залишатися різними об'єктами. Це практичний висновок синтезу літератури, а не результат уже проведеного експерименту Social.

Event extraction має щонайменше три окремі завдання: знайти згадку події, визначити її аргументи, встановити зв'язки між згадками. MAVEN Wang et al. містить 4 480 Wikipedia-документів, 118 732 згадки та 168 типів подій; експерименти авторів показали, що результати на великому загальному наборі гірші за оптимістичну картину малих датасетів. Це аргумент проти перенесення score англомовного news benchmark на українські Telegram-повідомлення без перевірки. Dataset корисний для онтології й контрольного тестування extraction, але не є gold для конкретного інциденту E1.

Для Social потрібні принаймні дві лінії подій. У physical-event layer входять прибуття, зібрання, переміщення, проникнення, застосування сили, травмування, госпіталізація. У communication-event layer входять публічна заява, публікація відео, спростування, виправлення й заклик. Перше повідомлення про госпіталізацію може бути опубліковано наступного дня; дата повідомлення не замінює час госпіталізації. Так само заява «ніхто не постраждав» є встановлюваною комунікаційною подією навіть тоді, коли її зміст пізніше заперечується.

Однаковий топонім не означає одну подію. Однакові люди можуть брати участь у різних діях, а одна дія може мати кілька просторових або часових частин. Доцільно визначити `incident` як контейнер, `conflict_episode` як фазу, `event` як дію або зміну стану, `event_mention` як конкретний фрагмент документа. Система не повинна зливати «поліція прибула», «поліція застосувала силу» та «поліція опублікувала заяву» в один кластер лише через спільний subject.

2. Порівняння перевірених підходів

Підхід	Досліджений результат	Застосовність і межа
Trigger detection / MAVEN	Великий набір із 168 типами показує складність general-domain extraction	Добрий candidate generator; trigger не підтверджує подію
Document-level argument generation / WikiEvents	Li et al. отримали абсолютні прирости 7,6 і 5,7 F1 на RAMS та WikiEvents	Контекст і coreference важливі; англомовні результати не означають UA/RU reliability
Joint entity-event coreference	Barhom et al. покращили ECB+ event coreference; joint над disjoint дав близько 1 F1 для подій	Аргументи допомагають, але помилкове entity merge поширює помилку
Multi-corpus feature vs neural CDCR	Bugert et al. знаходять кращу стабільність простішого feature-based методу між корпусами	Для невідомого Social-домену це сильний аргумент за простий контрольний baseline
Retrieval + fine-grained pair classification	Held et al. повідомляють +17,2 середніх F1 від multi-corpus training	Blocking знижує число пар; результат не є готовою валідацією UA/RU
Joint event relation extraction / MAVEN-ERE	Спільне навчання використовує взаємодію coreference, time, causal, subevent relations	Extracted causal relation означає текстове приписування причини, не causal identification
Date-wise timeline summarization	Ghalandari та Ifrim порівняли стратегії й покращили всі досліджені benchmarks простою комбінацією	Для Social краще date/event selection окремо від стислого викладу
Symbolic interval constraints	OWL-Time задає instants, intervals і ordering relations	Формальна коректність відносин, а не достовірність введених часових тверджень

Document-level extraction має практичну перевагу: людина чи назва органу часто з'являється в першому реченні, а дія або уточнення — в наступному. Li, Ji та Han запропонували conditional generation за event templates і WikiEvents із повною event/coreference annotation. Окрім приростів на двох наборах, вони повідомили 9,3 F1 приросту для informative argument extraction, де потрібне implicit coreference reasoning. Для Social варто запозичити template-based output з evidence span; це не підстава дозволити моделі генерувати відсутні аргументи E2.

DocRED окремо демонструє, чому sentence-only relation extraction недостатній: відношення між сутностями вимагають синтезу кількох речень. Набір створено з Wikipedia/Wikidata, а авторські baselines залишили задачу складною. Для Social це підтримує extraction з документа або логічно пов'язаного thread, але кожне відношення повинно зберігати конкретні supporting spans. Інакше довгий контекст створює нову можливість помилково поєднати людей із різних епізодів E3.

3. Temporal and Entity Reasoning

Entity Resolution і Event Resolution

У Barhom et al. event/entity mention представлені через lexical span, контекст і predicate-argument структуру. Joint modeling покращує benchmark, але error analysis показує принципову небезпеку: події з однаковими учасниками, які відбуваються в різний час, можуть бути помилково об'єднані. Це прямо відповідає Social: одна й та сама поліція, лікарня або група протестувальників не є унікальним ключем події E4.

Bugert, Reimers і Gurevych порівняли ECB+, Gun Violence Corpus і Football Coreference Corpus. Corpus-independent feature system мав нижчі абсолютні показники, але стабільніше переносився між корпусами; neural system міг бути успішним або невдалим залежно від домену. Вони також виявили overfitting на структурі ECB+. У Social не слід обирати модель лише за опублікованим найкращим ECB+ score E5.

Held et al. запропонували coarse candidate retrieval у learned embedding space і fine pairwise classification, замість повного порівняння всіх згадок. Їхній багатокорпусний експеримент дав середнє покращення 17,2 F1, що підтримує різноманітність training/evaluation domains. Для малого Social-корпусу математично можливий повний pairwise scoring, але retrieval стає корисним після накопичення багатьох інцидентів E6.

Рекомендований entity resolver має чотири рівні. Спочатку точні platform identifiers і документальні identifiers. Потім нормалізовані назви, transliteration і aliases, які створюють candidate pairs. Далі — спільний контекст, організаційна належність, час і посилання на профіль.

Нарешті — рішення `same`, `different`, `possible_same`, `unresolved` з provenance. Fuzzy name match без додаткових ознак не дозволяє зливати людей. Різні написання «Петропавлівська» і «Софіївська Борщагівка» слід зіставляти з різними place IDs; fuzzy similarity тут має знаходити ризик плутанини, а не виправляти місце автоматично.

Для event resolver рекомендується blocking за candidate incident, часовим інтервалом і місцем, але із separate escape route для згадок без часу чи місця. Pair features: тип дії, actor/victim/object roles, temporal compatibility, geographic compatibility, numeric attributes, provenance, polarity, modality і embedded quote boundaries. Суперечність у кількості учасників не завжди доводить різні події: це може бути одна дія з різними оцінками. Натомість два незалежно підтверджені неперетинні просторові та часові контексти — сильна `cannot_link` підстава.

Не слід робити ordinary connected components із усіх similarity-пар. Транзитивний ланцюг A~B і B~C може об'єднати несумісні A та C. Потрібна constrained agglomerative clustering або перевірка cluster-level compatibility перед merge. `same_as` має бути версіонованим рішенням, яке можна відкликати. Невизначені пари зберігаються ребрами `possible_same_event`, а не перетворюються на irreversible union-find merge.

4. Модель часу і незалежність часових полів

MATRES Ning, Wu та Roth є особливо придатним методологічним джерелом. Автори показали, що нечіткість event end-points ускладнює temporal annotation; multi-axis start-point схема в pilot expert annotation підвищила Cohen's kappa з діапазону .60 до .80. Це не універсальна точність автоматичного extractor, а результат кращого визначення annotation task. Для Social корисний принцип: не вимагати точнішого часу, ніж дозволяє матеріал E7.

Потрібні п'ять незалежних часових типів. `event_time` описує часовий інтервал дії. `publication_time` — час появи конкретного повідомлення. `observed_at` — момент отримання матеріалу колектором. `recording_time` — час запису медіа з зазначенням походження оцінки. `claimed_time` — часовий вираз, який повідомило джерело. Останній зберігає raw text, speaker і anchor. Кілька claimed times можуть суперечити один одному; система не повинна зберігати лише «найкращий» час і видаляти альтернативи.

Час представляється як `[earliest, latest]`, із `precision`, `timezone`, `timezone_basis`, `anchor_id`, `extraction_method`, `evidence_id`. День без години — інтервал дня, не опівніч; «близько 18» потребує explicit uncertainty convention. Для raw «вчора» anchor — час висловлювання або publication, якщо він справді відповідає висловлюванню. Для репосту чужого тексту anchor первинного тексту може відрізнятися від часу репосту. Неоднозначний anchor означає unresolved time.

OWL-Time надає vocabulary instants/intervals, positions, durations і topological ordering. Слід посилатися на stable Recommendation 2017 для базових конструкцій; поточна сторінка стандарту містить Candidate Recommendation Draft 2022, який W3C прямо називає work in progress. Система може зберігати сумісні JSON-поля без використання повного OWL reasoner E8.

Нормалізація через `zoneinfo.ZoneInfo('Europe/Kyiv')` придатніша для багатоінцидентної системи, ніж fixed UTC+2. У прочитаному `src/analysis/prep.py` fixed offset явно прив'язаний до листопада 2026; він не є помилкою цього конкретного зрізу, але його не слід повторно використовувати як універсальне правило. UTC timestamp і вихідний локальний вираз зберігаються одночасно; жодне timezone assumption не має залишатися прихованим.

Publication-time-before-event-time не завжди суперечність: повідомлення може анонсувати майбутній протест. Відповідна перевірка потребує modality `past_observation`, `future_plan`, `hypothetical`, `unknown`. Для верифікованого минулого запису можливе обмеження `recorded_at ≤ published_at`; для медіа з недостовірним metadata це лише candidate anomaly. Порушення не виправляється зсувом часу «до правдоподібного» значення.

5. Часовий граф і причинність

MAVEN-ERE містить окремі coreference, temporal, causal та subevent annotations: 103 193 coreference chains, 1 216 217 temporal relations, 57 992 causal relations і 15 841 subevent relations. Автори показали користь joint learning relations. Важливий для Social результат — явна різнотипність ребер; точний масштаб dataset не означає автоматичну застосовність до local messaging E9.

Побудова timeline починається з accepted temporal constraints, а не з LLM-наративу. У мінімальній реалізації достатньо `before`, `after`, `overlaps`, `contains`, `same_time`, `unknown`; складніші Allen relations додаються лише за потреби. Для строгого `before` надійна interval relation потребує `latest(A) < earliest(B)`. Якщо інтервали перетинаються, точний порядок невідомий, навіть коли середини інтервалів відрізняються. Partial order може мати кілька допустимих linearizations; система показує невизначені групи, а не обирає один порядок мовчки.

Constraint solver повинен відділяти hard anchors від extracted candidate relations. Цикл A before B before C before A означає конфлікт набору assertions; він не дає права видалити найменш авторитетне джерело автоматично. Потрібно записати inconsistent subset, перевірити event merge, timezone, quoting і extraction. Для малого корпусу достатні NetworkX DAG checks і interval arithmetic; Z3 або difference-constraints solver потрібні для складніших систем обмежень. Вибір solver не перетворює ненадійні inputs на підтверджені факти.

TimeBench Chu et al. охоплює широкий спектр temporal reasoning і показує суттєвий розрив між GPT-4/LLaMA2 та людьми, причому результати залежать від категорії задачі. Тому арифметику часу, transitivity й contradiction detection слід виконувати детерміновано. LLM корисний як parser неформального виразу з raw span, але не як остаточний часовий арбітр E10.

Причинність потребує окремих типів: `precedes`, `associated_with`, `claimed_cause`, `mechanism_hypothesis`, `causally_supported`. Фраза очевидця «після поста зібрався натовп» підтримує повідомлену послідовність; фраза «через пост» підтримує саме causal attribution цього мовця. Жодна не встановлює counterfactual effect. Для одиничного Social-кейсу зазвичай доступна evidence-supported process reconstruction, а не оцінка причинного ефекту медійної уваги. Потенційні shared causes, reverse causality, selective filming і publication delay повинні входити до alternative explanations.

6. Версіонована реконструкція без переписування історії

Потрібна append-only assertion store. Raw artifacts незмінні і content-addressed; нова версія сторінки створює новий snapshot. Далі extractor створює assertions з `valid_time` — коли описане могло відбуватися, та `transaction_time` — коли система це дізналася. Окремо зберігаються оцінки verification з model/config version. Це інженерна пропозиція, сумісна з часовими й provenance стандартами, а не окремий доведений класифікатор.

Якщо пізніша заява уточнює травми, новий `VerificationResult` посилається на попередній через `supersedes`; старий результат залишається доступним для `as_of` запиту. Відкликання повідомлення не видаляє факт його попередньої публікації. Водночас пізніше підтверджена травма не доводить автоматично її причинність, час отримання або точність початкової кількості постраждалих. Для кожного складового claim потрібне окреме рішення.

При зміні evidence система переобчислює лише downstream nodes: affected claims, event clusters, temporal constraints, conflict episode і report paragraphs. Dependency graph має дозволяти відповісти, які findings залежать від відкликаного джерела. Якщо підтримка зникає, finding переходить у insufficient evidence або conflicting evidence; попередній текст не повинен залишатися у фінальному звіті через кеш. Re-run ідентичного snapshot з однаковими deterministic rules дає той самий результат; stochastic model run зберігає власний run_id і output hash.

7. Timeline generation і багатодокументне резюме

Gholipour Ghalandari та Ifrim порівняли date selection і summarization стратегії за метриками повної timeline; проста комбінація покращила state of the art на всіх їхніх benchmarks. Це емпірична підстава розділяти selection і verbalization замість одного великого prompt «віднови подію». Їхні дані — news timelines, тому метрики не покривають усіх forensic ризиків Social E11.

У Social selection має бути evidence-aware: містити ключові physical events, комунікаційні зміни й unresolved disputes. Висока частота згадки не повинна бути критерієм істинності або автоматичної пріоритетності. Перший етап створює structured chronology; другий перетворює її на текст із дозволених event/claim records. Кожне речення має перелік assertion IDs і direct evidence locators. Висновок «повідомлено про травми» не повинен перетворюватися на «люди отримали травми внаслідок нападу» під час стискання.

Опис невизначеності є частиною timeline, а не приміткою наприкінці. Якщо відомо лише, що певна дія сталася між 18:00 і 20:00, її слід помістити в interval row. Якщо два джерела дають 18:20 і 19:10 та йдеться про одну коротку дію, показати обидві часові assertions і статус conflict. Якщо це можуть бути дві дії, залишити alternative event clustering. Timeline не зобов'язана мати суцільний ряд без прогалин.

8. Валідація компонента реконструкції

Автоматична перевірка повинна мати два рівні. Integrity checks перевіряють schema, locator, time bounds, referential integrity, immutable hashes, cycles і залежності; їх можна виконувати кожного запуску без людини. Correctness benchmark порівнює extraction і реконструкцію із раніше незалежно перевіреним набором подій. Збіг із внутрішнім LLM critic не є correctness gold. Початковий експертний benchmark потрібен під час розроблення, але повторна ручна розмітка кожного нового інциденту не є частиною runtime.

Метрики: event trigger span F1; event argument role/span F1; entity/event pair precision і recall; B^3/CEAF/CoNLL coreference scores; false merge rate; temporal relation macro-F1; interval coverage і width; contradiction recall; erroneous causal edge rate; evidence-locator coverage. Окремо рахуються UA/RU, short/long posts, reposts/originals, exact/relative/vague time. Gold mention і predicted mention режими слід показувати окремо, щоб помилка extraction не приховувалася за benchmark зі вже відомими triggers.

Найважливіший adversarial test: той самий actor, місце й тип дії у двох часових епізодах. Другий: два сусідні населені пункти зі схожими назвами. Третій: репост учорашнього тексту сьогодні. Четвертий: запланована дія проти здійсненої. П'ятий: один доказ скопійовано 50 разів. Система має зберегти event count, source root count і uncertainty, а не посилити підтримку від копій. Негативний результат означає потребу обмежити автоматичне merge/verification, не покращувати літературне формулювання звіту.

Для minimal viable system критерій integrity — нуль dangling evidence IDs, нуль непояснених часових циклів і нуль unsupported causal promotion у контрольних fixtures. Це contract invariants, а не довільні універсальні ML-пороги. Пороги auto-merge слід обирати за допустимим false-merge cost на frozen development benchmark; остаточний test залишається відкладеним. Якщо high-confidence merge недостатньо, output з окремими unresolved mentions є прийнятним автономним результатом.

9. Вплив на репозиторій і практичний бюджет

Прочитані наявні модулі `src/analysis/prep.py` і `src/analysis/media_fingerprints.py` вже містять корисні частини. `prep.py` зберігає normalized text і відокремлює частину сусідніх топонімів правилами; варто використати це як retrieval signal, не як geo-verification. `media_fingerprints.py` вже містить SHA-256, perceptual signatures, frame offsets і пряме застереження, що match не встановлює місце, час або істинність. Цю правильну межу слід зберегти. Немає підстав переписувати існуючий fingerprint компонент для реалізації event engine.

OmniEvent Peng et al. надає modular toolkit для event detection, argument extraction і relations, підтримує 15 English/Chinese datasets та розглядає evaluation pitfalls. Його доцільно використати як reference implementation або benchmark adapter, але не вимагати прямого production deployment для UA/RU. Саме ці дві мови не включені до заявленого coverage статті; off-the-shelf endpoint не є доказом придатності E12.

Мінімальна implementation proposal: нові `src/reconstruction/models.py`, `extract_events.py`, `resolve_entities.py`, `resolve_events.py`, `temporal_constraints.py`, `timeline.py`, `version_store.py`; це запропоновані файли, не встановлені наявні модулі. Зберігання — JSONL із schema_version плюс SQLite для індексів і dependency edges. Existing collectors подають immutable artifact references. Pydantic/JSON Schema перевіряють об'єкти; NetworkX — graphs; standard datetime/zoneinfo — timestamps; локальний multilingual encoder або provider-independent LLM — лише extraction/candidate scoring. Дорога graph database не є початковою необхідністю.

P0 — model/mention/assertion separation, independent timestamps, provenance locators, conservative identity, no automatic causal promotion, append-only verification history. P1 — cached multilingual extraction, incremental dependency invalidation, frozen UA/RU adversarial benchmark,

interval solver і source-level deduplication hooks. P2 — multi-corpus fine-tuning, learned coreference retrieval, повні OWL/RDF exports. Найскладніша модель не є пріоритетом: краща temporal/provenance дисципліна безпосередньо запобігає помилковому звіту навіть із незмінним extractor.

10. Додатковий evidence для cross-document evaluation

WEC Eirew, Cattan та Dagan розширює coreference за межі заздалегідь визначених topic clusters, використовуючи Wikipedia links; це корисний контроль проти надто зручного preclustering. Їхній WEC-Eng та baseline не перевіряють достовірність тверджень і не репрезентують Ukrainian social media. Задачу entity/event linking не слід непомітно підміняти fact verification E13.

TempReason Tan, Ng та Bing містить три рівні temporal reasoning і експерименти closed-book, open-book та reasoning QA. Навіть наявність retrieval не прибирає необхідності temporal span extraction і time-aware training. Це підтримує окрему перевірку часових відповідей у Social замість припущення, що RAG автоматично вирішує час E14.

11. Приклад роботи з неоднозначними повідомленнями

Нижче наведено умовний приклад, а не встановлені обставини кейсу Social. О 18:00 джерело A пише, що «поліція вже прибула». О 18:20 джерело B передає відео з коментарем «це зараз», а о 19:00 джерело C цитує A. Система може створити communication events для всіх трьох публікацій. Для physical event «прибуття поліції» у A є верхня часова межа 18:00, але нижня може залишитися невідомою. B може підтверджувати присутність поліції в кадрі, проте лише якщо візуальний зміст, location і recording time достатньо встановлені. C не створює другого незалежного підтвердження часу прибуття, оскільки його lineage веде до A.

Якщо на наступний день D пише «поліція прибула о 18:30», це не привід автоматично пересунути event на 18:30. Є щонайменше три альтернативи: помилка A, помилка D або два прибуття різних підрозділів. Event resolver повинен перевірити actor granularity, наприклад екіпаж проти підкріплення. Без цього temporal contradiction може бути штучним наслідком помилкового entity/event merge. Реконструкція повертає alternate interpretations із відповідними evidence IDs. Формулювання у звіті може чесно фіксувати, що час першого прибуття не встановлено, хоча сама присутність поліції підтверджується доступними матеріалами.

Аналогічно «нікого не госпіталізували» о 20:00 і «двох людей госпіталізували після опівночі» можуть бути сумісні. Система порівнює scope: місце, період, група людей, тип ушкодження і час висловлювання. Немає автоматичного contradiction між загальним раннім повідомленням і пізнішим розвитком подій. Натомість «жодної травми під час події не було» і незалежне документальне підтвердження травми в той самий період мають конфліктний scope, який потребує перевірки. Для числових тверджень треба відокремити точне число, нижню межу, приблизну оцінку та квантор «декілька».

12. Що означає повнота реконструкції

Повноту не можна оцінити числом слів у звіті або кількістю знайдених подій. Повнота extraction — частка benchmark events/arguments, які система знайшла. Повнота evidence retrieval — частка відомих gold supporting/contradicting records. Повнота реального світу лишається невідомою, якщо події не зафіксовані. Система має показувати coverage matrix за фазами, типами доказів і ключовими питаннями: час початку, дії сторін, постраждалі, інституційна реакція, завершення. Порожня комірка означає відсутність достатнього матеріалу для відповіді, а не відсутність самої події.

Ця відмінність дає автономній системі коректний stopping rule. Коли budget або retrieval saturation вичерпано, система завершує аналіз із переліком unresolved questions, retrieval attempts і доступних coverage indicators. Вона не мусить вигадувати завершення конфлікту для завершення документа. Для регулярного інкрементального запуску unresolved питання стають пошуковими задачами; нові матеріали додаються до provenance ledger і переоцінюють залежні висновки. Детермінований checkpoint не знімає epistemic uncertainty: він лише гарантує, що та сама версія доказів породжує простежувану версію реконструкції.

4. Evidence Verification and Provenance

4.1 Що саме дозволяє автоматична перевірка фактів

Для Social варто автоматизувати перевірку конкретного твердження відносно збережених доказів і дати зрізу. Це інша постановка, ніж визначення правдивості автора, політичної позиції або всього документа. Система повинна представляти твердження як пропозицію з актором, дією, об'єктом, місцем, часовим інтервалом, кількісними та модальними обмеженнями. «Особа повідомила про травму», «особа мала травму», «травму отримано під час інциденту» і «травму спричинив конкретний учасник» потребують різних доказів. Підтвердження першого твердження не переноситься автоматично на останні три. Автоматичний extraction має зберігати оригінальний фрагмент, мовця, заперечення, умовність і невизначений час.

FEVER (Thorne et al., NAACL 2018) встановив корисний принцип: правильний verdict повинен супроводжуватись необхідним набором evidence sentences. Корпус містить 185 445 штучно створених із Wikipedia claims; початкова система отримала 31,87% для спільної вимоги правильного label і evidence, проти 50,91% без вимоги доказів. Це історичні результати конкретного baseline, а не оцінка моделей 2026 року. Для Social важливе саме розділення завдань retrieval і verdict; штучні англомовні claims не підтверджують перенесення якості на українські конфлікти. FEVER

FEVEROUS додав таблиці, списки та змішані evidence sets. Переможець shared task 2021 досяг FEVEROUS score 27%, на 9 пунктів вище baseline. Це показує, що навіть у визначеному корпусі Wikipedia знаходження і правильне поєднання доказів значно складніше, ніж classification already-retrieved text. Для Social рішення про документи, офіційні реєстри й таблиці не повинні ґрунтуватися на плоскому тексті без заголовків колонок, приміток, рядків і контексту. Водночас FEVEROUS не моделює повністю суперечливі свідчення очевидців. FEVEROUS task

AVeriTeC наближує задачу до відкритого вебу: 4 568 реальних claims із fact-checks 50 організацій, питання-відповіді, URL доказів і пояснення verdict; міжанотаторська κ=0,619. Значення для Social полягає у decomposition перевірки на підпитання: хто саме зробив заяву; до якого місця вона відноситься; чи існує первинний документ; коли він став доступним; чи описує він той самий епізод. Цей корпус англомовний, уже відібраний fact-checkers і переважно текстовий, тому він не є готовим gold для локального інциденту. AVeriTeC dataset

Критичне уточнення результатів: у shared task 2024 переможець отримав 63% AVeriTeC score, baseline 11%; бал нараховувався лише за правильний verdict при достатньому evidence score. Організатори виявили в knowledge store fact-checking articles, які створювали leakage, і випустили очищений store. У виданні 2025 змінили тест, обмежили моделі відкритими вагами, ввели іншу evidence metric Ev2R та hardware/time constraints. Переможець отримав 33,17% спільного score, не «33,17% точності тверджень». Порівнювати 63 і 33,17 як спад здібностей неправильно. 2024 task, 2025 task

4.2 Retrieval має перевіряти альтернативи

Пропонована для Social процедура використовує два потоки пошуку. Перший шукає первинні матеріали й прямі підтвердження, другий - заперечення, виправлення, альтернативну локалізацію та інший час. Пошук не починається з формулювання «чому claim правдивий». Запити генеруються з нейтральних entities, дат, конкретних дій, цитат і варіантів написання. Для кожного claim система фіксує початкові запити, знайдені URL, відхилені результати, помилки завантаження та бюджет пошуку. Обмеження бюджету призводить до стану `search_incomplete`, а не до твердження про відсутність факту.

Мінімальний retrieval baseline - lexical BM25 плюс dense multilingual embeddings, reciprocal-rank fusion, дедуплікація та reranker. Так можна знаходити точні імена й номери документів, а також семантичні перекази. Embedding similarity визначає кандидата; вона не означає support. На рівні passage потрібні окремі `supports`, `contradicts`, `mentions`, `insufficient_context`, із claim target та точним evidence span. До retrieval candidate додаються сусідні речення, заголовок, дата й атрибуція цитати. Якщо evidence лише повторює claim без доступу до первинного свідчення, це `repeats`, а не незалежне corroboration.

Cross-document retrieval повинен зберігати різні позиції, а не усувати незручні суперечності reranking-ом. Для пошуку спростувань корисні контрастні запити з тими самими entity/time/place, але альтернативними значеннями; для claim «40 осіб» треба перевіряти не тільки буквальне «40», а й інший підрахунок, категорію людей та часовий зріз. Числа нормалізуються разом із одиницею, scope і квантором. «До 40», «приблизно 40», «40 за весь день» і «40 одночасно» не еквівалентні.

4.3 Походження інформації та незалежність

П'ять каналів і три медіа, які посилаються на одного очевидця, створюють вісім публікацій і одне відоме первинне свідчення. Об'єктом source independence є не домен, а конкретна підстава знання щодо конкретного claim. Один журналіст може незалежно спостерігати прибуття поліції та водночас переказувати чуже повідомлення про травми. Тому залежність має бути ребром між evidence items або повідомленнями, обмеженим claim і часом, а не глобальною властивістю джерела.

Класична робота Dong, Berti-Équille і Srivastava (VLDB 2009) показала, чому majority voting за наявності копіювання спотворює truth discovery, і запропонувала Bayesian source dependence. Її важлива обмовка: спільні правильні значення не доводять copying, а copier може додавати власну незалежну інформацію. Для Social це аргумент на користь обліку lineage, але не дозвіл автоматично переносити ймовірнісну модель з tabular single-truth data на соціальні свідчення. Source dependence

Визначати lineage потрібно послідовно: явний forward/citation/URL; точна цитата та named speaker; exact/near-duplicate family; earliest observed publication; спільна медіаоснова; лише потім inferred dependency. Для inferred edges зберігаються підстави й альтернативи. Найраніший знайдений допис має назву `earliest_observed`, а не `original_source`: невидимий приватний чат, видалений пост або недоступне відео можуть передувати йому. Shared wording може походити з пресрелізу, спільної трансляції або незалежного цитування документа; самостійне corroboration не встановлюється відмінністю тексту.

W3C PROV-O дає стандартні `Entity`, `Activity`, `Agent` і зв'язки `wasDerivedFrom`, `wasQuotedFrom`, `wasRevisionOf`, `hadPrimarySource`. Стандарт описує provenance, а не вірогідність. Для Social байти HTML/відео, фрагмент, claim extraction і висновок мають окремі ID; OCR/ASR/LLM extraction - це Activities із версією інструмента. Наявність hash доводить незмінність збережених байтів відносно зафіксованої копії; вона не доводить автентичність зображеної події. PROV-O

Практичне правило aggregation: жодного множення support через кількість copies. Evidence збираються у provenance families. Для відомих derivation links сім'я має одну первинну підставу; для невідомої незалежності показуються нижня межа підтверджених незалежних origins і кількість additional origins з невстановленим lineage. Не слід замінювати це формулою «вісім незалежних джерел» через відсутність виявленого copying. Одна якісна первинна відеофіксація може підтверджувати обмежений видимий факт; універсальна вимога двох джерел також не є достатньою або необхідною умовою істини.

4.4 Джерело має профіль доказової придатності

Єдиного науково валідованого рейтингу reliability для всіх джерел одного інциденту немає. Social має зберігати окремі характеристики: direct observation, domain competence, identification, access to underlying material, documentary backing, scope, independence, corrections, known conflicts. Репутація органу не замінює перевірку його доступу до конкретного факту. Невідомий автор може надати достовірне відео, а офіційна заява - описувати лише відомості, доступні на ранній час. Твердження про професію або статус очевидця також потребує своєї перевірки й не є автоматичним verdict щодо всього запису.

Офіційне «повідомлень про постраждалих не надходило станом на 17:00» має інший scope, ніж «постраждалих не було». Пізніша госпіталізація може не суперечити першому формулюванню, але суперечити другому, якщо йдеться про той самий час, місце й категорію людей. Контекстуалізація перед contradiction detection повинна перевіряти сумісність actors, predicates, quantifiers, timestamps і speaker commitments. Несумісні речення про різні епізоди не треба зливати в `Conflicting`.

ClaimReview придатний як зовнішній формат публікації вже виконаного fact-check: `claimReviewed`, `itemReviewed`, `reviewRating`, author/date/URL. Він не описує повністю суперечливі evidence families, сліди невдалого пошуку та історію переоцінювання. Тому його варто зробити export-view над внутрішнім графом, а не головною базою Social. Схема не робить rating об'єктивним і не встановлює універсальну шкалу truth. ClaimReview

4.5 Open-world verification та зміна оцінки

Рекомендована модель не застосовує closed-world assumption: відсутній факт не стає false. `Unverified` означає, що перевірка ще не виконана; `Insufficient Evidence` - перевірка виконана в певному corpus/time/budget, але достатніх підстав немає; `Not Verifiable` - формулювання не має спостережуваних критеріїв або виходить за доступний тип даних. `Supported` і `Refuted` завжди відносні до описаного scope і збережених evidence sets; `Conflicting` означає, що допустимі несумісні підстави залишились нерозв'язаними. Слово `Unknown` використовується для невідомих полів, а не як прихована половина truth score.

Стан verification не варто зводити до однієї ймовірності: модель може бути впевнена, що джерело щось стверджує, але не мати даних для реальності події. Зберігати потрібно щонайменше extraction confidence, evidence-to-claim relation confidence, provenance certainty та assessment status. Калібрована ймовірність дозволена лише для конкретної задачі, перевіреної на зовнішніх мітках; LLM-фраза «впевненість 95%» не є такою оцінкою.

Кожне переоцінювання створює новий `VerificationResult` зі `assessed_at`, `evidence_cutoff`, `supersedes`, policy/model versions, доданими й відкликаними evidence IDs та причиною переходу. Попередній результат не редагується. Виправлення джерела зберігається як нова версія повідомлення; retraction не видаляє історичний запис і не робить автоматично правдивим протилежне твердження. Перераховуються лише downstream findings, що залежать від зміненого evidence. У звіті окремо подаються «що було публічно заявлено тоді» та «що підтримують матеріали на дату зрізу».

5. Claim–Evidence–Provenance Graph Framework

Твердження в публікації, спостереження людини, зафіксований файл і аналітичний висновок — різні типи об'єктів. Мінімальна модель містить Source (видавець/мовець), Artifact (незмінний знімок документа чи медіа), Passage (точний текстовий діапазон, сторінка, кадр або аудіоінтервал), Claim (атомарне твердження), Observation (заявлене безпосереднє сприйняття), EvidenceAssessment (відношення фрагмента до твердження), Event, Dependency та Finding.

EvidenceAssessment має тип supports, contradicts, contextualizes, quotes, rebuts, irrelevant або ambiguous. Він вказує точний passage, метод, версію класифікатора, пояснення scope та оцінку невизначеності. Retrieval result без знайденого passage — кандидат на перевірку, не доказ. Одне довге твердження варто розбити на перевірювані атоми: число присутніх, добровільність перебування, травма, час травми, причина травми й особа, яка її завдала, — різні claims.

Модель W3C PROV-DM / PROV-O є доречною основою обміну provenance: Entity, Activity, Agent; derivation, quotation, primary source, revision, attribution, usage та generation. Вона описує походження запису, але не встановлює правдивість твердження. Schema.org ClaimReview придатний для експорту публічного fact-check із назвою твердження, датою, рецензентом і рейтингом; це не повна доказова модель і не алгоритм перевірки.

Копії формують lineage graph. Якщо B цитує A, C переказує B, D публікує синдикований текст C, то для підрахунку незалежної підтримки маємо один upstream корінь, доки кожна публікація не додає окреме незалежне спостереження. Якщо походження невідоме, independence має значення unknown; невідоме не можна прирівняти до незалежного. Подібні тексти, спільні посилання, цитати й репости допомагають генерувати candidate dependency edges. Самі по собі вони не доводять організовану координацію.

Не задавати одному джерелу глобальний рейтинг правдивості. Зберігати окремо близькість до події, компетентність саме щодо claim, первинність матеріалу, залежність від інших публікацій, часову близькість, редакційні виправлення й суперечності. Офіційне джерело може мати

прямий доступ до одних фактів і не мати його до інших; очевидцеві може бути відома видима дія, але не медичний діагноз чи подальший процес.

Стани перевірки: supported_within_scope, refuted_within_scope, conflicting_evidence, insufficient_evidence, unverified, not_verifiable, superseded. Кожен стан має scope, as_of, множину доказів та підставу переходу. Refuted вимагає позитивного несумісного доказу в межах формулювання. Відсутність знайденого підтвердження означає insufficient_evidence, а не відсутність події. Superseded позначає застарілу оцінку, але не видаляє її. Усі статуси залежать від доступного корпусу й дати зрізу.

Рекомендовані інваріанти: кожне емпіричне речення має посилання на passage і artifact hash; supported/refuted потребують assessment; publication time не підмінює event time; часові інтервали, що перекриваються, не отримують вигаданий строгий порядок; causes не виводиться лише з before; зміна джерела спричиняє нову версію похідного висновку, а не тихе переписування історії.

Для початку достатньо SQLite з таблицями nodes, edges, assertions, artifact_versions, assessments і report_runs, foreign keys та unique constraints. JSONL забезпечує обмін і replay. RDF/JSON-LD PROV додається як export. Graph DB не потрібна до появи виміряного навантаження, яке виправдовує супровід окремої системи. Відкритий світ RDF/OWL узгоджується з OSINT: відсутній зв'язок означає невідоме, а не false. Повнота має бути явно обмежена snapshot-ом і coverage statement.

6. Social Conflict Analysis

6.1 Що можна автоматизувати з науковою опорою

Практично придатна основа - Protest Event Analysis: система кодує спостережувані дії, учасників, цілі дій, місце, час і джерела повідомлення. Вона створює перевірювані мікроепізоди, а потім пов'язує їх у розвиток конфлікту. Автоматичне виведення психологічних мотивів, суспільної підтримки або причин конфлікту із самих дописів не має такого самого доказового статусу. Професійний аналітик повинен отримувати опис того, які дії та публічні позиції підтверджуються матеріалами, а також перелік обставин, для яких потрібних даних немає.

CASE 2021 експериментально розділив document relevance, sentence relevance, event sentence coreference та extraction. Для останнього завдання найкращі результати в різних умовах становили 66,20-78,11 F1-macro; document classification мала 77,27-84,55. Англійська, португальська та іспанська були мовами навчання й оцінювання, а гінді - додаткового evaluation для document classification. Це прямий аргумент на користь каскаду з окремими метриками: добре відбирати протестні новини ще не означає правильно відтворювати конкретні дії. Ці показники не оцінюють українські Telegram-повідомлення і не можуть бути використані як заявлена точність Social. Hürriyetoğlu et al., 2021.

Для Social рекомендовано локальну предметну онтологію з можливим відображенням у ACLED/CAMEO. Основні дії: прибуття; зібрання; публічний заклик; виголошення вимоги; блокування; спроба проникнення; фізичний контакт; застосування сили; затримання; медична допомога; переміщення; офіційна заява; відкликання чи виправлення; розходження учасників. Публікація допису - окрема інформаційна дія. Вона може описувати фізичну подію, але не стає цією фізичною подією.

6.2 ACLED, CAMEO/ICEWS і GDELT: реальна придатність

Підхід	Що варто запозичити	Межа застосування
ACLED	Кодбук дій, actor/associated actor, точність дати й місця, revision discipline	Дані створюють досвідчені дослідники; це не готова автономна система й не еталон кожного локального факту
CAMEO/ICEWS	Подання actor-action-target; розрізнення заяви, вимоги, протесту, примусу і фізичного нападу	Категорії розроблялися для політичних/міжнародних взаємодій; їх слід адаптувати для локального конфлікту
GDELT	Пошук медійних згадок, зовнішніх матеріалів, часової уваги та кандидатів для retrieval	Машинно виділена згадка не доводить саму подію; coverage, переклад, повторення й extraction змінюють кількості
CASE shared tasks	Окрема перевірка relevance, extraction, coreference; multilingual transfer controls	Новинні корпуси й мови відрізняються від коротких українських/російських соціальних повідомлень

ACLED має чіткі правила відмежування peaceful protest, protest with intervention та excessive force against protesters. У його документації також пояснено, що нуль у fatalities може означати відсутність повідомлених смертей або невідоме число, а за невизначеної множини загиблих можуть застосовуватися умовні значення 3 чи 10. Для індивідуальної доказової реконструкції Social ці конвенції копіювати не слід: `unknown`, `reported_zero` і `confirmed_zero_with_scope` мають залишатися різними значеннями. Оцінка чисельності повинна містити джерело, інтервал, область спостереження та метод, а не одну псевдоточну цифру. ACLED Codebook, ACLED Fatalities.

CAMEO формалізує взаємодію джерельного актора, дієслова і цільового актора; початкові категорії містять statements, demands, protest, coercion та assault. Це корисний словник типів дії, але жоден код сам по собі не перевіряє правдивість повідомлення. Goldstein-подібну шкалу не слід застосовувати як універсальну міру тяжкості локального насильства: однаковий код може приховувати різні масштаби та невідомі наслідки. CAMEO Codebook.

Критичний аналіз Wang et al. показує проблеми reliability і validity великих автоматичних event databases ICEWS/GDELT. Це фундаментальна робота 2016 року, включена як виняток до часової рамки. Її практичне застосування: Social зберігає кожен рядок зовнішнього event feed як extraction іншої системи із власним provenance, а не безпосередньо встановлений факт. Для GDELT треба повертатися до тексту джерела; первинний SOURCEURL також не є повним списком незалежних підтверджень. Wang et al., Science, офіційний codebook GDELT.

6.3 Automated Social Conflict Analysis Framework

Запропонований нижче фреймворк є інженерною операціоналізацією досліджених методів, а не окремим емпірично відкаліброваним класифікатором. Його вихід - `ConflictEpisode`, що посилається на граф подій і доказів. Епізод має часовий інтервал, просторовий контур, перелік спостережуваних сторін, дій, публічних вимог, установчих і оспорюваних обставин. Епізод можна описати і за відсутності надійних імен усіх людей.

Ролі. Для кожного `Entity -> Event` зв'язку зберігати `role`, evidence span, asserted_by, valid_time, verification state. Допустимі ролі: працівник установи; представник органу; військовослужбовець; учасник зібрання; родич за заявою; місцевий мешканець за заявою; журналіст; свідок; автор повідомлення; коментатор; невідомий. Роль може бути підтвердженою в одному епізоді та невідомою в іншому. Публічна підтримка не доводить фізичної участі; зйомка біля натовпу не доводить участі в протесті; форма не доводить службових повноважень; присутність на фото не доводить організаційного керування. Це формальні правила на рівні графа, які не потребують людини для кожного нового випадку.

Сторони. Кластери учасників формуються за спостережуваною взаємодією та публічною self-identification, а не за етнічними, мовними чи зовнішніми ознаками. Повідомлення поліції про роль особи зберігається як атрибутована заява поліції до перевірки. Якщо є лише анонімне відео, допустимо створити `unknown_person_17` і описати видиму дію. Об'єднання цієї сутності з конкретним іменем вимагає окремого перевірюваного зв'язку. Спільна роль або політична позиція не є достатньою умовою entity merge.

Предмет конфлікту. Зберігати шість окремих полів: `trigger`, `public_demands`, `stated_grievances`, `institutional_context`, `structural_hypotheses`, `information_interpretations`. Безпосередній привід може бути лише версією сторони. Вимога має конкретного мовця й цитату. Інституційний контекст спирається на документацію, а структурна гіпотеза вимагає історичних або порівняльних даних. Не слід генерувати причинне пояснення мобілізації лише тому, що воно правдоподібно звучить.

Класична праця Dynamics of Contention порівнює вісімнадцять епізодів і розглядає механізми brokerage, формування категорій та зміни колективних акторів. Для Social її корисний принцип - аналізувати взаємодію у процесі, а не припускати незмінні сторони. Перенесення назв механізмів у автоматичний звіт саме по собі не підтверджує, що механізм діяв у конкретному кейсі. McAdam, Tarrow & Tilly, 2001.

Публічна позиція. Формат: хто висловив, на яку дату, до якої вимоги/події/інституції, у якому матеріалі, чи це цитата, переказ або висновок системи. Один актор може змінити позицію. Приписування позиції всій групі за висловлюванням однієї людини має блокуватися, якщо представництво не встановлене. Розбіжність між позиціями родичів, установи та журналістів є самостійним результатом; система не повинна штучно зводити їх до єдиного консенсусу.

6.4 Динаміка ескалації та деескалації

Для опису розвитку доцільний вектор індикаторів, а не один opaque escalation score. Компоненти: нові заклики до фізичного зібрання; повідомлені/підтверджені прибуття; видимий діапазон чисельності; зміна просторового доступу; фізичне блокування; застосування сили з actor-target; допомога постраждалим; затримання; переговори; зміна вимог; припинення фізичної взаємодії. Кожна компонента має стан `observed`, `reported`, `disputed` або `not_observed_in_available_material`. Останній стан не означає, що подія не відбулася.

Для оперативної автоматики переходи задає state machine з condition evidence. Наприклад, `gathering -> physical_confrontation` потребує виділеної події фізичного контакту й достатнього контексту, але не збільшення лайків чи слів «штурм» у дописах. Паралельні епізоди можуть мати різний стан. Не слід примусово вкладати весь інцидент у лінійну універсальну сходинку ескалації: переговори та насильство можуть відбуватися одночасно на різних ділянках.

Слід вести дві часові серії: `physical_event_series` з підтверджених або чітко атрибутованих подій; `information_attention_series` з публікацій, повторів, переглядів і заяв. Порівнювати їх можна, але потрібні різні знаменники. Пік повідомлень може з'явитися через публікацію одного популярного відео наступного дня, тоді як фізичний конфлікт уже завершився. Автоматична фраза «ескалація конфлікту о 21:00» без незалежного фізичного індикатора має відхилятися валідатором.

Препринт Razakason et al. (2026) досліджує затримки включення африканських подій у щотижневі випуски ACLED за червень 2024-червень 2025. Автори знаходять структуровані, а не випадкові затримки: понад половина подій потрапляє в базу за два тижні; часові лаги залежать від характеристик події та контексту. Це не параметри для українського кейсу, але прямий аргумент зберігати `first_observed_at` окремо від `event_time` і не інтерпретувати останні неповні години як деескалацію. Статус джерела - препринт. arXiv:2603.25964.

6.5 Інституційна реакція та причинний вплив

Інституційну реакцію можна автоматично вимірювати через час першої заяви щодо конкретного твердження, час уточнення, наявність відповіді на конкретні питання, публікацію документів, зміну формулювань і повідомлені процесуальні дії. Кожен показник потребує початкової точки: перша знайдена згадка не обов'язково дорівнює першій публічній згадці. Затримку відповіді не можна автоматично називати приховуванням, а виправлення - доказом умисної неправди.

SCCT Coombs (2007) розглядає зв'язок кризових реакцій і репутаційних загроз. Для Social доречне кодування видимої стратегії відповіді, наприклад заперечення, корекції або визнання відповідальності. Проте без експериментів чи опитувань не можна оцінити, як конкретна відповідь змінила довіру людей. Коментарі описують позиції доступних авторів, а не рівень інституційної довіри всього населення. Coombs, 2007.

Висновок про інформаційний причинний вплив потребує окремої ідентифікації. Спочатку будують часовий порядок, потім перевіряють доступ актора до повідомлення, свідчення зміни дії, конкурентні причини й механізм. Один інцидент із неповними цифровими слідами зазвичай дає лише `temporal_association` або `actor_reported_reason`. Для сильнішого висновку потрібні індивідуальні дані exposure/behavior, природний експеримент, переконливий інструмент або дослідницький дизайн із контрольними подіями та перевірюваними припущеннями. Додавання Granger-тесту до publication counts не встановлює вплив на учасників.

6.6 Контроль якості конфліктного аналізу

Еталон розвитку системи має бути episode-level: події, ролі, час, evidence spans і невідомі обставини, а не просто кінцевий текст. Потрібні окремі помилки `role_without_evidence`, `motive_as_fact`, `group_generalization`, `media_peak_as_physical_escalation` та `causal_edge_without_design`. Для фізичних переходів обчислювати precision/recall і часове відхилення; для тверджень про мотиви та причинність - частку непідтверджених висновків. Zero tolerance у контрактних правилах означає, що такі записи блокуються в поточному звіті, а не емпіричну гарантію нульової помилки моделі на всіх випадках.

Для негативного контролю підійде кейс зі старим відео й пізнім піком публікацій: система має збільшити інформаційну активність, але не створити новий фізичний епізод. Інший контроль - зміна офіційної позиції без нової фізичної події: змінюється institutional communication, а не реконструкція часу госпіталізації. За відсутності достатніх матеріалів завершений автономний звіт може містити змістовний аналіз суперечностей і чесно невизначену траєкторію фізичного конфлікту.

7. Multimodal Evidence

7.1 Доказові завдання потрібно розвести

Схожість медіа, зміст сцени, геолокація, час зйомки, цілісність файлу та відповідність підпису - різні завдання. Одна модель або confidence score не закриває їх разом. Відео може бути справжнім записом пожежі, але з іншої дати й місця. Текст може правильно називати населений пункт, але неправильно описувати причину пожежі. Навіть правильно геолокований запис не показує прихованих подій поза кадром.

NewsCLIPpings експериментально досліджує випадки, де зображення й текст не змінювали, але поєднали з неправильним контекстом. Це обґрунтовує обов'язкове тестування media-caption relation, а не лише пошуку deepfake. Luo, Darrell & Rohrbach, 2021. VERITE додає modality balancing: ті самі текст і зображення з'являються у правдивих та оманливих парах, щоб модель не вгадувала за однією модальністю. У фінальному висновку журнальної роботи наведено лише 52,1% accuracy для multiclass MMD. Це сильне застереження проти автономної категоричної верифікації реальних інцидентів одним image-text detector. Papadopoulos et al., 2024.

7.2 Що вже є у Social

`src/analysis/media_fingerprints.py` уже реалізує SHA-256, pHash63/dHash64 для вибіркових кадрів, варіанти повного кадру й обрізання, двобічне зіставлення, часову узгодженість matched frames і receipts із параметрами. Код явно позначає пороги як exploratory/uncalibrated, не приписує збігам геолокацію чи дату, а timestamp відео відділяє від часу публікації. Це корисна наявна основа, яку не потрібно переписувати. Основний дефіцит - її результат поки не є повним медіадоказом із контекстом і provenance графа.

Файл також прямо попереджає про ризик збігу заставок, пропуск коротких фрагментів та хибне тлумачення offset як напряму копіювання. Пропозиція - зберегти descriptive output і додати навколо нього автоматичні контролі та downstream gates. У production необов'язково вимагати ручного перегляду кожної пари: неперевірені кандидати залишаються `candidate_shared_sequence`, а factual report використовує лише той клас тверджень, який пройшов окрему валідацію. Поточну рекомендацію коду про ручний перегляд можна виконувати на benchmark-наборі під час розроблення.

7.3 Multimodal Evidence Validation Pipeline

Етап	Засіб / метод	Структурований вихід	Умова подальшого використання
Приймання	SHA-256, ffprobe/PyAV, незмінний оригінал	MediaAsset; bytes; codec; PTS; acquisition receipt	Оригінал доступний, hash стабільний
Сегментація	Shot boundaries; VAD; покадрова часова сітка	Clip/shot/audio intervals	Усі похідні мають source hash та offsets
Текст і звук	OCR; ASR; optional diarization	Bounding boxes; timed tokens; speaker labels	Це extraction, не підтвердження сказаного/видимого
Копії	Наявні pHash/dHash; learned retrieval за потреби	Exact match / near-copy candidate / aligned interval	Геометрична й часова перевірка, calibrated thresholds
Пошук контексту	Image retrieval; цитовані upload pages; archive lookup	Earlier occurrence; candidate scene/site/time	Збережені сторінки й дати retrieval
Простір і час	Local feature matching; maps; weather/sun constraints	Location/time constraints з підставами	Альтернативи перевірені; немає inference з EXIF лише
Зміст	VLM extraction + конкретні кадри й transcript	Observable propositions, not visible/unclear	Evidence-to-claim relation перевірена
Граф і звіт	Claim/evidence links; deterministic gates	Media verification result з unresolved facets	Кожний висновок обмежений перевіреною гранню

Практичний мінімум працює локально: ffmpeg/PyAV для декодування, OpenCV для кадрів і геометрії, наявні fingerprints, CPU OCR і вибіркова ASR. GPU слід витрачати на спірні або важливі фрагменти після дешевого retrieval, а не на повне semantic captioning тисяч майже однакових відео. Однакові кадри й транскрипти кешуються за hash+model_version+parameters; повторне використання не створює нового незалежного доказу.

7.4 Пошук старих відео та різних записів однієї події

SHA-256 відповідає на питання про ідентичні байти. pHash/dHash працюють як дешеві near-copy candidates. DISC21 спеціально оцінює modified-copy retrieval у корпусі мільйона reference images із багатьма distractors; benchmark включає crop, re-encoding, edits і складні трансформації. Для Social корисний тест на precision за дуже низької base rate: 99% accuracy на переважно різних парах може бути практично марною. Douze et al., 2021/2022.

Не треба завантажувати весь DISC21 для робочого аналізу одного інциденту. Локальний transformation suite включає водяний знак, чорні поля, crop, blur, дзеркало, зміну швидкості, монтаж зі старим кадром, вставку заставки й кілька секунд співпадіння. Positive controls - відомі перетворені копії, hard negatives - подібні пожежі/натовпи й однакові телевізійні рамки. У звіті потрібні matched clip intervals та coverage; одне схоже зображення не доводить, що весь ролик однаковий.

Інші камери тієї самої події можуть не мати жодного near-duplicate кадру. Для них потрібні узгоджені scene landmarks, часові сигнали, спільні видимі дії та аудіоподії. LoFTR використовує coarse-to-fine dense local matching і показує переваги на indoor/outdoor correspondence benchmarks, включно зі складними малотекстурними зонами. Це доступний інструмент для geometric verification кандидатів, але не готовий доказ геолокації: повторювані фасади, рекламні щити й невірний reference image створюють false matches. Sun et al., CVPR 2021.

Негативний результат пошуку означає лише, що в доступному індексі не знайдено копію. Він не доводить оригінальності. Найраніша знайдена публікація дає `first_known_publication`, а не гарантовані recording time, авторство чи origin. Старіша архівна поява того самого фрагмента може спростувати твердження «знято сьогодні», але не всі можливі твердження про подію.

7.5 ASR, OCR та мовці

Whisper навчався на 680 тисячах годин multilingual/multitask supervision і демонстрував сильну zero-shot переносимість. Це обґрунтовує його як практичний локальний baseline, але не як transcription ground truth. Radford et al., ICML 2023. У Careless Whisper аналіз 13 140 англомовних сегментів дав 1,4% сегментів із вигаданими послідовностями у відповідному API/корпусі; особливості non-vocal duration були важливими. Це не оцінка поточного Whisper на українських відео, проте доводить сам клас ризику. Koenecke et al., FAccT 2024.

Практичні запобіжники: VAD до ASR; не подавати тишу на генерацію; word timestamps; no-speech/log-prob features як cues, а не calibrated truth; окрема мітка overlap/noise; повторне декодування сумнівних фрагментів альтернативною моделлю; збереження аудіо відрізка для кожної цитати. Узгодження двох ASR не доводить правильності. Критичні імена, числа, заперечення й слова про зброю або травми потребують підвищеного threshold; без нього автономний звіт має давати обережний переказ або `unintelligible`, а не точну цитату.

pyannote.audio 2.1 розділяє segmentation, speaker embeddings та agglomerative clustering. Його оцінювання показує залежність від домену, тому потрібно тестувати саме шумні багатоголосі записи. Speaker diarization відповідає «які фрагменти належать одному мовцю у заданому матеріалі», а не «хто ця людина». Результати `speaker_0`, `speaker_1` не можна автоматично перетворювати на імена чи прив'язувати між різними роликами без окремої доказової процедури. Bredin, Interspeech 2023.

Для OCR мінімальна система порівнює Tesseract чи PaddleOCR на власному frozen українсько-/російськомовному наборі screenshots, документів і відеокадрів. PaddleOCR 3.0 має окремі OCR, document parsing та information extraction компоненти; їх треба розрізняти. Виведений layout або extracted JSON не є автентифікацією документа. Зберігати polygon, crop, text, language, confidence і model version. Особливо перевіряти дати, знаки заперечення, ідентифікатори й числа. PaddleOCR 3.0 Technical Report, препринт 2025.

7.6 Видимі дії, час і геолокація

ActionFormer показав 71,0% mAP за tIoU=0,5 на THUMOS14 і 36,6% average mAP на ActivityNet 1.3, але це action localization у відповідних benchmark-категоріях. Такі результати не підтверджують здатності розрізняти законне затримання, незаконне утримання чи умисне приховування доказів. Для Social корисна локалізація інтервалу руху/контакту/пожежі; юридична та причинна інтерпретація має належати окремому claim reasoning. Zhang, Wu & Li, ECCV 2022.

VLM отримує конкретний clip і запит про observable propositions: кількість видимих людей як інтервал, положення об'єктів, послідовність видимих дій. Заборонені semantic jumps: «лежить» не означає «мертвий»; «людина у формі» не означає «поліцейський»; «вогонь у дворі» не означає «знищення доказів». Для кожного результату потрібні frame timestamps, область кадру й перелік того, чого запис не показує. Підпис автора зберігається у text claim, а не в visual observation.

Геолокація будує candidate sites з топонімів/OCR/landmarks; перевіряє геометрію кількох незалежних елементів і просторову сумісність; повертає координату з точністю та unresolved alternatives. Семантичний текст VLM «це схоже на Софіївську Борщагівку» не проходить цей gate. Час зйомки може бути інтервалом із lower/upper bounds від першої доступної публікації, видимих годинників, освітлення, погодних даних і синхронізованих подій. Кожна ознака має припущення: годинник міг бути неправильним, weather не унікальна, тіні потребують геометрії й не завжди відомої орієнтації.

EXIF, container creation_time й overlay timestamp зберігаються як claimed metadata. Їх можна змінити; social platform могла re-encode файл і видалити первинні поля. C2PA перевіряє cryptographic binding і assertions у provenance chain, але специфікація прямо не прирівнює provenance до фактичної істинності. Відсутність manifest не доводить підробку, а валідний manifest не доводить правильність сцени чи підпису. C2PA explainer.

7.7 Мінімальні критерії автономного використання

Для кожного asset потрібна матриця окремих статусів: `bytes_integrity`, `near_copy`, `scene_match`, `location`, `recording_interval`, `content_claim_relation`, `editing_continuity`, `speaker_attribution`. Загальний ярлик `verified_video=true` недостатній. Монтажний clip зберігає кілька segment-level lineage; доведений збіг одного сегмента не переноситься на решту. Аудіо може бути накладеним, а subtitle - авторським коментарем; ці потоки мають окремі зв'язки.

Benchmark має тестувати старе справжнє відео з новим підписом, сучасне нерелевантне відео, однакові заставки різних подій, різні камери однієї події, монтаж із двох дат, тишу/шум для ASR, виправлений документ і crop зі зниклим запереченням. Метрики: copy retrieval precision/recall з low-FPR operating point; temporal alignment error; OCR CER/WER для critical fields; ASR WER плюс hallucinated-span rate; DER для diarization; false geolocation rate; supported observable proposition rate; out-of-context detection risk-coverage. Жодна з них окремо не дорівнює загальній правдивості доказу.

Автономність забезпечується обмеженням дозволених висновків відповідно до фактично перевірених граней. Система може коректно завершити аналіз і повідомити: «знайдено спільний відеофрагмент; місце та час зйомки не встановлено; заяву про приховування доказів цей запис не підтверджує». Це повноцінний доказовий результат, який не потребує вигадувати пропущений контекст або переривати кожен кейс для ручного рішення.

7.8 Пріоритети інтеграції та завершення перевірки

P0: з'єднати наявні outputs із доказовим графом. `media_fingerprints.py` має віддавати versioned evidence records через адаптер, зберігаючи current algorithm ID і raw receipts. Потрібні `asset_id`, `derived_from`, `segment_start_ms`, `segment_end_ms`, `assertion_scope` і `known_limitations`. Критерій завершення: кожне речення про медіазбіг у звіті веде до конкретної пари asset hashes та matched intervals; жодне автоматично не формулює дату, місце чи напрям копіювання. Залежності від OCR або великої vision model для цього етапу немає.

P0: обмежити physical-conflict conclusions. Новий `conflict_episode` builder отримує лише події, а не сумарні views чи числа дописів. Він може приєднувати information attention як окремий шар. Критерій завершення: контрольний корпус із штучно збільшеною кількістю репостів не змінює фізичну траєкторію; виправлена офіційна заява змінює лише належні claims та evaluations. Новий модуль повинен мати структурований список unresolved points для кожної сторони без автоматичної вимоги ручного розбору.

P1: додати сегментовані OCR/ASR. Субтитри, отримані `src/youtube_subtitles_collect.py`, слід зберігати разом із platform source і quality status. Новий локальний extractor створює окремий transcript, а не перезаписує платформний. `src/analysis/youtube_content_analyze.py` можна використовувати як існуючий downstream consumer; його реальна логіка потребує окремої інспекції перед реалізацією. У межах цього дослідження підтверджено існування модуля, але не валідовано всі його перетворення. Завершення: ASR/OCR unit fixtures забезпечують точну прив'язку offsets до незмінного asset та збереження нерозбірливих сегментів.

P1: створити геометричну перевірку медіакандидатів. Локальний OpenCV matching із RANSAC дешевший за повне LoFTR-декодування всього корпусу. Learned matcher запускати для складних кандидатів, коли classical baseline не має достатнього recall. Benchmark порівнює false matches, time cost і accepted coverage на заздалегідь розділених сценах. Критерій вибору - нижчий ризик неправильної локації за корисного coverage, а не найвищий середній similarity. Якщо жодний варіант не проходить target risk, система залишає location unresolved.

P2: temporal action localization і масштабний retrieval. ActionFormer-подібний extractor виправданий, коли є повторюваний великий обсяг untrimmed відео й локально перевірена таксономія видимих дій. Для кількох десятків коротких роликів доцільні shot segmentation та evidence-scoped VLM proposal, що проходить окремі gates. Learned copy embeddings і зовнішній image index потрібні лише після вимірювання пропусків наявного fingerprint baseline.

Усі контрольні набори фіксуються один раз під час розроблення: hashes, дозволені перетворення, expected scopes і істинні невідомі значення. Регресійний запуск автоматично порівнює останню pipeline version з frozen baseline та попереднім release. Новий кейс

обробляється без ручного анотування; при domain shift, низькому coverage чи провалі gates він отримує обмежений висновок. Для звіту важливо також зберігати coverage matrix: які медіафрагменти доступні, які не декодовано, для яких немає аудіо/контексту/локації. Без цієї матриці впевнене формулювання «усі відео підтверджують» є неперевірюваним.

8. Autonomous AI Analysis

8.1 Порівняння перевірених архітектур

Підхід	Що перевірено дослідженням	Наслідок для Social
One-shot LLM / довгий контекст	Може синтезувати матеріал, але не забезпечує коректності цитат або повного охоплення	Контрольний baseline, непридатний як єдине evidence engine
Звичайний retrieve-then-generate	Підставляє знайдені passages; не перевіряє їхню достатність	Потрібні окремі retrieval і entailment gates
Self-RAG	Навчена модель вирішує коли retrieve і генерує reflection tokens	Корисний comparative baseline, не готова гарантія для UA/RU
CRAG	Retrieval evaluator запускає різні дії, включно з вебпошуком і filtering	Перенести ідею routing, зберігаючи відхилені докази
Two-step long-context RAG	CTU AIC виграв efficiency-constrained AVeriTeC 2025	Почати з простого відтворюваного pipeline
Agentic iterative verification	Пошук наступного підпитання з попередніх результатів	Обмежені цикли для unresolved claims, не безмежна дискусія
Multi-model debate	Може давати кращі відповіді на окремих benchmarks, має correlated errors	Жодного підвищення proof status через саме голосування

Self-RAG (Asai et al., ICLR 2024) використовує спеціально навчені reflection tokens, а не лише інструкцію «перевір себе»; моделі 7B/13B показали переваги над наведеними авторами ChatGPT/RAG baselines у QA, verification і citation quality. Це емпіричний аргумент за adaptive retrieval і явну оцінку support. Але pretrained англомовний checkpoint та benchmark wins не дають готової UA/RU інцидентної надійності; порівняння слід повторити локально. Self-RAG

CRAG (Yan et al., 2024) окремо оцінює якість retrieval, обирає наступну retrieval дію та фільтрує passages; автори перевірили метод на чотирьох datasets короткої й довгої генерації. Для Social прийнятна інженерна адаптація - за низького retrieval support розширити пошук або зупинити висновок. При цьому генеративне «decompose/recompose» не повинно замінювати raw evidence: вилучений фрагмент зберігається з offset, а reformulation має власний provenance. CRAG, arXiv version

AVeriTeC 2025 є найпрямішим доказом практичної доступності обмеженого автономного verification: відкриті моделі, один GPU із 23GB, до хвилини на claim; CTU AIC простим двоетапним long-context RAG отримав перше місце. У таблиці task paper час переможця 53,67 s/claim, joint score 0,3317 проти baseline 0,2023. Це controlled knowledge-store retrieval, не повна вартість відкритого вебзбору, відеоаналізу та case report. На CPU можна запускати менші quantized models повільніше, але жодної еквівалентної точності без локального benchmark не встановлено. CTU AIC

8.2 Гнучкість агента всередині контрольованого workflow

Рекомендована автономність Social - workflow з явними станами, чергами й контрольними умовами. Coordinator формує questions з unresolved claims, викликає search/fetch/extract/compare, і передає structured results до deterministic gate. LLM може пропонувати запит або аргумент; він не має права створювати джерело, citation locator чи новий support edge без прочитаного artifact. Кожен tool result має machine-readable `success`, `partial`, `blocked`, `not_found` і raw receipt. Відмова fetch не перетворюється на `not_exists`.

Цикли retrieval мають ліміти за числом запитів, latency, токенами та новими незалежними evidence families. Зупинка визначається виконаним доказовим правилом, вичерпаним бюджетом або відсутністю нової інформації, а не «відчуттям завершеності» моделі. Незавершені claims залишаються у готовому звіті як unresolved; система може завершити роботу без людини, не

завершивши встановлення кожного факту. Під час наступного оновлення повторно відкриваються лише відповідні claims або події, а не весь корпус.

Модель не повинна бачити текст іншого verifier перед власною початковою оцінкою, якщо порівняння претендує на незалежні model judgments. Проте навіть isolated model outputs не є незалежними цифровими свідченнями: вони можуть використовувати однакові навчальні дані, search index і однакову помилкову новину. Correlated Errors in Large Language Models (Kim et al., ICML 2025) дослідив понад 350 моделей; на одному leaderboard вони давали однакову помилкову відповідь у 60% випадків, коли обидві помилялися. Висока точність і різні providers не усували кореляції. Correlated errors

MAST (Cemri et al., 2025 preprint) дослідив понад 1600 traces семи multi-agent frameworks і виокремив 14 failure modes у system design, inter-agent misalignment і task verification; κ=0,88 стосується анотації taxonomy, а не truthfulness самих агентів. Практичний висновок - модельні ролі мають бути вузькими, результати типізованими, а termination і source checks контролюються кодом. Для нового інциденту multi-agent architecture варто приймати лише після paired ablation проти одноагентного pipeline при однаковому бюджеті. MAST

8.3 Побудова звіту з findings, а не з вільної пам'яті

ALCE (Gao et al., EMNLP 2023) окремо оцінює correctness і citation quality. На ELI5 навіть найкращим дослідженим системам бракувало повного citation support приблизно половину разів. Тому наявність URL наприкінці абзацу не є достатньою. Для кожної atomic assertion потрібен конкретний fragment або достатній evidence set; одна цитата не повинна «прикривати» кілька доданих тверджень про мотив, причину й кількість учасників. ALCE

У запропонованому Social renderer приймає тільки `AnalyticalFinding`, а не raw chat history. Finding містить `claim_ids`, `evidence_ids`, `verification_result_ids`, scope, alternatives і дозволений тип висловлювання: factual, attributed, conflicting, unresolved, analytic hypothesis. Language model може редагувати граматику, але не розширювати actors, час, модальність або причинність. Після генерації другий extractor розбиває фінальний текст на atomic assertions; кожна повинна зіставитися з findings. Невідповідність призводить до локального rewrite або видалення непідтвердженої частини, а не до пошуку цитати під уже вигадане речення.

Контроль цитати складається з трьох шарів. Перший deterministic: artifact існує, hash і locator правильні, цитований текст міститься у snapshot. Другий semantic: evidence підтримує саме сформульовану assertion, з потрібними числами, entities і часом. Третій provenance: passage не є лише повтором іншої цитати та не відкликаний на поточний зріз. Перший шар можна забезпечити повністю кодом, другий має помилки NLI/LLM і потребує calibration, третій частково залежить від повноти source lineage.

9. Reliability and Uncertainty

9.1 Метрики перевіряють різні властивості

FActScore (Min et al., EMNLP 2023) розкладає генерацію на atomic facts і рахує частку підтриманих knowledge source. У досліджених biographies ChatGPT отримав 58%, автоматичний estimator мав невелику агреговану похибку; це не означає низьку помилку кожного окремого judgement. Важливе обмеження самої роботи - precision не карає за коротку відповідь або часту abstention, а Wikipedia biography setting не має типових для інциденту конфліктних evidence. Для Social використовувати атомарність, але додати completeness, contradictions і temporal scope. FActScore

VeriScore (Song, Kim, Iyyer, Findings EMNLP 2024) спеціально розрізняє verifiable та unverifiable content; human evaluation claim extraction проведено на восьми long-form tasks, порівняно 16 models. Рейтинг на biography generation не обов'язково переносився на long-form QA. Для Social це підтримує окреме кодування оцінок, гіпотез і factual assertions та заборону використовувати один загальний leaderboard score як обґрунтування автономної придатності. VeriScore

SAFE (Wei et al., NeurIPS 2024) автоматично виділяє facts і перевіряє їх через iterative search. На приблизно 16 тисячах facts SAFE узгоджувався з crowd annotators у 72% випадків; у вибірці 100 disagreements adjudication віддала йому перевагу у 76%. Автори повідомляють понад 20-кратне

зниження annotation cost. Це доводить корисність scalable evaluator, але не безпомилковість і не перевагу над експертним локальним OSINT gold. SAFE перевіряє search support; він також може успадкувати помилку відкритого вебу. SAFE

QAFactEval (Fabbri et al., NAACL 2022) порівнює question-answering і entailment оцінку factual consistency. Оптимізація QA components дала 14% середнього поліпшення над попередніми QA metrics на SummaC benchmark; QA і NLI дали взаємодоповнювальні сигнали. Для Social це обґрунтовує два незалежні за функцією checks: чи citation entail assertion та чи відповіді на ключові questions збігаються між report і evidence. Це різні діагностичні механізми, проте вони також не є безпомилковими judges. QAFactEval

9.2 Автоматичний evaluator також потребує зовнішньої перевірки

AVeriTeC 2025 прямо повідомляє: evidence metric 2024 мала correlation близько нуля з людськими ratings coverage і relevance. Заміна на Ev2R дала Spearman 0,404 для coverage та 0,244 для relevance, Pearson 0,406 і 0,242 на subset із 198 system evidence annotations. Автори все одно виявили приклади, де evidence з неправильними числами отримувало високу оцінку через подібні формулювання. Отже, новий metric кращий за попередній у цьому тесті, але не gold. Social має зберігати disagreement cases й регулярно перевіряти evaluator на frozen evidence pairs із numbers, negation, dates, speaker shifts та corrections. AVeriTeC 2025, Table 7

Автоматичними hard checks можна контролювати reference validity, required fields, timestamp ordering, ID consistency, точні числові величини, duplication invariance й повноту заповнення mandatory sections. Factual entailment, правильність entity merge та повнота реконструкції потребують model assessment і зовнішнього еталона під час розроблення. Твердження «усі assertions мають citation» вимірюється автоматично; твердження «усі citations достатні» потребує validated judge. Метрики не варто підсумовувати в довільний single quality score: фінальний звіт має окремий vector risk/coverage/provenance/temporal consistency.

9.3 Abstention і calibration

Selective prediction дозволяє моделі відповідати лише на підмножині, де очікуваний ризик достатньо малий. Визначити `coverage = N_answered/N_eligible`, `risk = N_wrong_answered/N_answered`; показувати всю risk-coverage curve, а не precision при майже нульовій coverage. Для allegations про конкретну особу помилка має іншу ціну, ніж пропуск другорядного часу прибуття. Threshold визначається прийнятою функцією втрат і калібрується на незалежних incidents; універсальний «confidence>0.9» не має наукового сенсу.

Farquhar et al. (Nature 2024) оцінюють semantic entropy, кластеризуючи семантично еквівалентні sampled answers. Серед 30 task/model combinations середній AUROC 0,790, проти 0,691 для naive entropy; автори прямо зазначають, що метод не виявляє всі систематичні confidently wrong answers. Для Social це допоміжний uncertainty feature для дорогих unresolved claims, а не заміна retrieval. Ten-sample estimation збільшує вартість; systematic wrong agreement лишається можливим. Semantic entropy

Conformal Language Modeling (Quach et al., ICLR 2024) калібрує stopping/rejection rules для набору кандидатних відповідей, щоб набір з потрібною ймовірністю містив прийнятну відповідь. Гарантія стосується визначеної процедури, calibration data й припущень, не того, що будь-який вибраний текст є правильним. У Social доцільніше почати з conformal prediction sets для обмежених verdict labels або ризик-контролю assertions. За domain shift нових конфліктів exchangeability може порушуватися, тому без додаткової перевірки не можна обіцяти «95% істинності» звіту. Conformal Language Modeling

ConU (EMNLP Findings 2024) досліджує conformal uncertainty для black-box LLM у open-ended NLG з iid calibration. Це підтверджує технічну можливість calibration без доступу до logits. Але відкриті інциденти мають залежні copies, різні languages, retrieval failures і неповний gold. Практичне застосування повинно використовувати incident-level splits, окремі UA/RU strata і provenance-family grouping; якщо calibration непридатна до нового domain, система повертає `calibration_out_of_scope` і посилює abstention. ConU

9.4 Конкретні acceptance gates і перевірки стійкості

Перший gate є контрактом даних: 100% report assertions мають valid finding ID, будь-які external factual assertions без evidence mapping блокуються. Це engineering invariant, не емпірична гарантія truth. Другий gate - frozen adversarial suite: неправильні entity IDs, mismatched dates, swapped numbers, відсутній locator, циклічний dependency link і retracted evidence повинні активувати відповідні stop/uncertain states. Для critical deterministic cases допускається нуль known violations; для semantic tests потрібно оцінювати довірчі межі помилок і розмір еталона.

Третій gate перевіряє independence invariance: дублювання одного testimony в 1, 10, 100 та 1000 publications не має збільшувати кількість confirmed origins чи змінювати support state лише через copies. Видалення первинного документа повинно залишити історію derivations, але зменшити доступність direct evidence; система не створює нових origins на заміну. Для uncertain dependency створюються сценарії merge/split families і показується зміна висновку; це sensitivity analysis, не довірчий інтервал population truth.

Четвертий gate - time-travel evaluation: система запускається з evidence cutoff до і після офіційного correction. Відповідь до correction має відображати доступні тоді відомості, після - пояснювати зміну, зберігаючи попередню version. Документи, published після cutoff, не можна використовувати як contemporaneous support; для retrospective reconstruction вони дозволені з явно пізнім `available_at`. Retrieval index і модельні знання самі можуть давати temporal leakage, тому evaluator повинен вимагати passage support навіть для правильно вгаданого verdict.

П'ятий gate - robustness to missingness: прибрати випадкові passages, цілі source families, найбільший канал і всі офіційні або всі неофіційні матеріали окремими сценаріями. Правильна реакція на втрату evidence - менша coverage, ширша невизначеність або зміна supported scope. Вигадане заповнення прогалин вимірюється unsupported claim rate і invented event edge rate. Відсутність падіння точності при втраті evidence може бути ознакою memorization/leakage; це потрібно перевіряти, а не автоматично трактувати як robustness.

Після одноразової зовнішньої валідації frozen controls запускаються без людини для кожної зміни model/prompt/parser/retrieval. На новому incident автоматично контролюються contracts, evidence coverage та distribution drift. Перевірка frozen набору не доводить ground truth нового кейсу, але виявляє регресії. Якщо новий випадок виходить за валідовані мови, типи медіа чи ролі, система все одно створює звіт із точною межею: встановлені документовані обставини та unresolved питання. Автономний output не потребує обов'язкового analyst approval кожного епізоду; він потребує чесного обмеження висновків власною доказовою базою.

9.5 Мовне перенесення та межі незалежної валідації

Більшість наведених end-to-end benchmarks використовують англомовні claims, певну редакційну процедуру відбору та попередньо підготовлений knowledge store. Social має короткі українські й російські повідомлення, суржик, транслітерацію, цитати з пропущеним контекстом та часто недоступні медіафайли. Тому переклад усіх claims англійською може бути додатковим retrieval channel, але оригінальний текст лишається джерелом доказової оцінки. Машинний переклад здатен змінити заперечення, відмінок особи, модальність або різницю між «побачив» і «почув». Translated passage повинен мати provenance до оригіналу і власний статус машинного перетворення.

Практична development validation використовує frozen cases із чітко відомими позитивними та негативними доказовими зв'язками; corpus split робиться за інцидентами і source families. Якщо одна цитата потрапляє і до train, і до test як різні URL, оцінка generalization завищується. Для multilingual evaluator слід показати results UA, RU, mixed language та translated input окремо. Для fact-check retrieval потрібні recall@k і adequate-evidence recall; для verdict - macro F1, confusion matrix та joint evidence-verdict score; для report - unsupported assertion rate, contradiction omission rate та qualified completeness. Випадок із правильною відповіддю при неправильному evidence вважається помилкою joint task.

Надійність не вимагає щодня нового ручного анотування, але вимагає періодичної зовнішньої перевірки репрезентативних нових типів помилок. Такий аудит може бути пакетним після накопичення drift signals. До того часу автономна система зберігає output із більшою abstention, а не підвищує confidence через самоперевірку. Якщо первинна інформація закрита,

незалежність джерел невідома або відео не має верифікованої локалізації, повний звіт повинен містити ці прогалини як результат дослідження. Повнота звіту означає також повноту опису невстановлених питань; вона не означає заповнення кожного поля позитивним фактом.

10. Experimental Validation

Для кожного контрольного випадку фіксувати corpus version, cutoff date, очікувані стани, ground-truth passages, заборонені твердження, модель/правила та критерій проходження. Частина збурень може бути синтетичною, але її не слід представляти як статистику реальних подій.

Контроль	Метод	Метрики	Типова помилка
Відомий інцидент	Заморожений корпус і незалежна хронологія з першоджерелами	Event/argument precision-recall; похибка інтервалу; entity-link precision; evidence passage support	Пропущені фази або фальшиве точне упорядкування
Суперечливі свідчення	Реальні incompatible claims і paraphrase контроль	contradiction recall; false-resolution rate; abstention accuracy; selective risk	Модель голосує за більшість джерел
Масове копіювання	Контроль «один корінь — N цитат» проти незалежних однакових повідомлень	lineage edge precision/recall; cluster purity; похибка кількості незалежних roots	Копії рахуються як свідки
Виправлена офіційна заява	Первинна версія, correction і retraction із часом	Збереження старої оцінки; зв'язок revisions; час до superseded	Стирання ранньої версії
Неповний корпус	Пропуски випадково, за платформою і часовими блоками на 20/50/80%	Unsupported claim rate; зміна abstention; хибні event links	Заповнення прогалин вигаданими причинними містками
Нерелевантне відео	Старі ролики, crop, mirror, re-encode, still frames і правильний контроль	Recall пошуку; false same-event link rate; не підтверджені часові/геолокаційні висновки	Схожий кадр прирівнюється до того самого інциденту

Пороги обираються за ціною помилок, а не універсальним accuracy. Для висновків про осіб і причинність ціна хибного твердження висока, тому важливіша висока precision та коректне утримання від висновку. Для пошукової черги прийнятний recall, якщо всі результати позначені як кандидати. Вибір threshold виконується на development set; оцінка — на замороженому тесті з інтервалами й незмінним протоколом.

Автоматичні release gates перевіряють JSON schema, наявність passage locator, відповідність цитати архівованому artifact hash, відтворення чисел query-ом, timezone і тип часу, unresolved contradictions, межі джерельного coverage та відсутність причинних формулювань без підстав. NLI/LLM entailment перевірка — лише скринер mismatch, не фінальне судження. Для кожного нового інциденту людина не потрібна в циклі обробки; заморожений acceptance suite можна запускати при оновленні коду/моделі й за графіком, а розширення еталонного набору залишається періодичним завданням якості.

11. Proposed Architecture for Social

Локальний read-only огляд проведено на commit a5b3a5b8f4af2398d9edd163f00708329f0fd8bc. Це фіксує стан checkout, не майбутні зміни. Вже є практична основа: src/archive_sources.py зберігає HTML gzip, SHA-256 і час отримання; src/source_watch_collect.py керує watchlist, версією extraction та архівними snapshots; src/analysis/media_fingerprints.py обчислює SHA-256 і sampled pHash/dHash із вирівнюванням відеокадрів і явно позначає пороги як exploratory; src/analysis/youtube_evidence_audit.py описує scope й межі зібраних матеріалів; src/analysis/prep.py формує корпуси для подальшого аналізу. Нові етапи мають інтегруватися після цих адаптерів.

Pipeline:

collect/archive → immutable artifacts → passages/OCR/transcripts → candidate claims/entities/events → provenance graph → retrieval and evidence assessment → temporal constraint checking → conflict/event projections → deterministic quality gates → constrained report.

Fetch, content hashes, schema, timestamps, joins, quote locators, count derivation і interval arithmetic мають бути deterministic. Retrieval можна скласти з BM25/full-text і multilingual embeddings. ML/LLM extraction повертає typed JSON candidates із span-ами та версією, ніколи не змінює первинний матеріал. Entity, event і claim resolution є кандидатним link prediction; незрозумілий зв'язок залишається unresolved. Causal inference і статистичні агрегати належать окремим процедурам, а не генеративному тексту.

Кожен LLM крок читає недовірені джерельні дані; джерельний текст не має права задавати агенту інструкції. AgentDojo перевірив 97 задач і 629 security test cases та показав уразливості tool-using агентів у benign і prompt-injection умовах. Тому планувальник може лише викликати allowlisted read-only retrieval, extraction і report tools; не має credentials, shell доступу чи дозволу надсилати/публікувати дані. Обробку adversarial текстів вести як дані, з окремим control plane.

Інкрементальність: повторний capture створює нову версію Artifact. Parser/model зміна створює нові derived assertions із provenance; минулі результати залишаються відтворюваними. Поява виправлення інвалідовує тільки похідні висновки, що залежать від зміненого джерела. Report run фіксує snapshot IDs, cutoff, версії tools/models, параметри retrieval, правила status transition і hashes. Для моделі без стабільної platform ID зберігати URL, capture time, hash і відношення між версіями.

12. Data Models and Interfaces

Інтерфейс — JSONL для записів, SQLite як локальна база, JSON Schema як обов'язковий контракт. Companion schema файл описує десяток об'єктів і обов'язкові поля.

- **Source:** source_id, kind, publisher/handle, locator, claim-specific metadata, assessment provenance.
- **Artifact:** artifact_id, source_id, URL, hash, MIME, fetched_at, status, raw archive locator, asserted created/modified times.
- **Evidence:** evidence_id, artifact_id, exact text offsets/page/frame/audio range, extracted content, extractor version, coverage flags.
- **Claim:** claim_id, proposition, normalized slots, attributed speaker/state, assertion/quote/modality, event-time target, first known appearance.
- **Event:** event_id, predicate, actor/object/place references, open time interval, precision, support links, alternative event links and state.
- **SourceDependency:** parent/child IDs, quotes/repost/syndicated/translated/same-media/unknown relation, exact basis, model, confidence.
- **Contradiction:** claim pair or incompatible event slots, temporal/spatial scope, evidence references, unresolved/superseded/resolved state and rationale.
- **VerificationResult:** claim ID, state, as_of, scope, support/contradiction passages, process version, transition from prior state, caveats.
- **ConflictEpisode:** event range, attributed participants/roles, publicly stated demands, observed actions, institutional responses, source coverage, hypotheses separate from observations.
- **AnalyticalFinding:** sentence/object, finding type, claim/evidence IDs, citations, state, alternatives, model/run, quality-gate results.

Часові записи вказують time_kind, raw_value, nullable UTC interval, timezone_status, granularity, source passage, extractor and confidence semantics. Діапазон не зводити до midpoint. Record transaction time (коли Social записав assertion) окремий від valid/event time. Це дає bitemporal history: що система зберегла на той час і який період стверджує матеріал. Model confidence має назву model_score, вказує calibration population/version і не означає ймовірність того, що світовий факт правильний.

Схема має забороняти evidence-less findings, подвійну лічбу lineage, твердження про відсутність на основі незнайдених результатів, event_time з publication timestamp без атрибуції, causes без

causal warrant, claims без scope/as_of та report без snapshot version. Усі uncertain fields nullable й мають код причини.

13. Implementation Priorities

P0 — доказова цілісність

- Додати immutable Artifact/Evidence/Claim/Finding записи з точними passage offsets, hashes, URL, capture time й tool versions, повторно використавши src/archive_sources.py і src/source_watch_collect.py.
- Додати source-dependency graph і root source clusters, не змінюючи початкові артефакти.
- Задати стани перевірки open-world; refuted вимагатиме контрдоказу, insufficient evidence не перекладати як false.
- Розділити час події/заяви/публікації/запису/збору; інтервали і валідатор суперечностей.
- Генерувати висновки лише через IDs із passage-level anchors; блокувати числа, дати та причинність, які не відтворюються/не мають warrant.
- Залишити агентам read-only allowlisted tools; блокувати prompt injection side-effects.

P1 — точніша реконструкція й переоцінка

- Candidate event/entity/claim coreference з high-precision merge; сумнівний same_as не зливає ID.
- Додати bitemporal versioning, provenance-aware invalidation і diff звітів.
- Retrieval: SQLite FTS/BM25 plus multilingual embeddings, rerank лише top-k; зберігати retrieval candidates та причини ранжування.
- Побудувати acceptance harness на шість контрольних типів; тестувати модельні оновлення на незмінному корпусі.
- Застосувати модулі src/analysis/prep.py, src/analysis/media_fingerprints.py та src/analysis/youtube_evidence_audit.py як наявні джерела функціональності й scope records.

P2 — додаткове покриття

- Експорт PROV JSON-LD, графова БД після профілювання, OCR/audio/video pipelines, cross-lingual retrieval, C2PA validation.
- Підключення ACLED/GDELT/ICEWS/CAMEO як контекстних або candidate datasets тільки при відповідності одиниці спостереження та періоду. Вони мають власні coverage, coding rules і затримки; не є автоматичним ground truth локальної хронології.
- Причинний аналіз лише якщо дизайн і дані дозволяють; часовий пік дописів є описовим збігом, не причинним ефектом.

14. Scientific References

Джерела згруповані за напрямами у відповідних розділах. Дублікати з однаковими URL вилучені. Операційні стандарти і препринти збережені з явним статусом.

1. Xiaozhi Wang et al. (2020). “MAVEN: A Massive General Domain Event Detection Dataset.” EMNLP, 1652-1671. DOI 10.18653/v1/2020.emnlp-main.129. Джерело. 4,480 documents; 118,732 event mentions; 168 types. Published comparative experiments indicate real-world ED remains difficult. Межа: English Wikipedia; event detection is not truth verification or Social transfer validation.

2. Sha Li; Heng Ji; Jiawei Han (2021). “Document-Level Event Argument Extraction by Conditional Generation.” NAACL-HLT, 894-908. DOI 10.18653/v1/2021.naacl-main.69. Джерело. Absolute improvements 7.6 F1 on RAMS and 5.7 F1 on WikiEvents over next best compared model; informative argument extraction +9.3 F1. Межа: English datasets, benchmark-specific baselines and evaluation; not UA/RU reliability.

3. Yuan Yao et al. (2019). “DocRED: A Large-Scale Document-Level Relation Extraction Dataset.” ACL, 764-777. DOI 10.18653/v1/P19-1074. Джерело. Baseline evaluation confirms challenge of inter-sentence relation extraction. No unverified exact score asserted here. Межа: Relations inferred from text do not establish real-world facts; Wikipedia differs from posts.

4. Shany Barhom; Vered Shwartz; Alon Eirew; Michael Bugert; Nils Reimers; Ido Dagan (2019). “Revisiting Joint Modeling of Cross-document Entity and Event Coreference Resolution.” ACL,

4179-4189. DOI 10.18653/v1/P19-1409. Джерело. Paper reports +9.5 CoNLL event F1 over then best comparator; joint vs disjoint +1.2 entity / +1 event F1. Error analysis warns same actors at different times can false-merge. Межа: ECB+ English benchmark; errors in entity resolution can cascade into event resolution.

5. Michael Bugert; Nils Reimers; Iryna Gurevych (2021). “Generalizing Cross-Document Event Coreference Resolution Across Multiple Corpora.” Computational Linguistics 47(3), 575-614. DOI 10.1162/coli_a_00407. Джерело. Feature-based system lower absolute performance but more consistent across corpora; neural generalization hit-or-miss; ECB+ structural overfit identified. Межа: Three corpora do not exhaust Social languages, formats, or incidents.

6. William Held; Dan Iter; Dan Jurafsky (2021). “Focus on what matters: Applying Discourse Coherence Theory to Cross Document Coreference.” EMNLP, 1406-1417. DOI 10.18653/v1/2021.emnlp-main.106. Джерело. Multi-corpus training improves average performance by 17.2 F1 across evaluated datasets according to paper. Межа: Benchmark and training mix specific; retrieved neighborhoods can miss unexpected links.

7. Qiang Ning; Hao Wu; Dan Roth (2018). “A Multi-Axis Annotation Scheme for Event Temporal Relations.” ACL, 1318-1328. DOI 10.18653/v1/P18-1122. Джерело. Pilot expert IAA improves from kappa in conventional .60s to .80s. Межа: IAA improvement is not automatic temporal extraction accuracy; startpoints do not fully represent event duration.

8. Simon Cox; Chris Little, editors (2017). “Time Ontology in OWL.” W3C Recommendation, 19 October 2017. Джерело. Normative modeling resource; no empirical model-accuracy claim. Latest /TR/owl-time page instead identifies a 2022 Candidate Recommendation Draft. Межа: Ontology consistency does not ensure truth or reliability of input assertions.

9. Xiaozhi Wang et al. (2022). “MAVEN-ERE: A Unified Large-scale Dataset for Event Coreference, Temporal, Causal, and Subevent Relation Extraction.” EMNLP, 926-941. DOI 10.18653/v1/2022.emnlp-main.60. Джерело. 103,193 coreference chains, 1,216,217 temporal, 57,992 causal, 15,841 subevent relations. Joint modeling improves performance per authors. Межа: Textually annotated causality is not causal identification; English domain transfer not established.

10. Zheng Chu; Jingchang Chen; Qianglong Chen; Weijiang Yu; Haotian Wang; Ming Liu; Bing Qin (2024). “TimeBench: A Comprehensive Evaluation of Temporal Reasoning Abilities in Large Language Models.” ACL, 1204-1228. DOI 10.18653/v1/2024.acl-long.66. Джерело. Experiments on GPT-4, LLaMA2 and other tested models reveal substantial human-model gap and differences across reasoning categories. Межа: Evaluated model versions and tasks; cannot infer exact error for 2026 models or Social.

11. Demian Gholipour Ghalandari; Georgiana Ifrim (2020). “Examining the State-of-the-Art in News Timeline Summarization.” ACL, 1322-1334. DOI 10.18653/v1/2020.acl-main.122. Джерело. Simple combination improves over state of art on all tested benchmarks; introduced larger longer-span timeline dataset. Межа: News summary evaluation does not cover evidential independence, wrong claims or hidden omissions.

12. Hao Peng; Xiaozhi Wang; Feng Yao; Zimu Wang; Chuzhao Zhu; Kaisheng Zeng; Lei Hou; Juanzi Li (2023). “OmniEvent: A Comprehensive, Fair, and Easy-to-Use Toolkit for Event Understanding.” EMNLP System Demonstrations, 508-517. DOI 10.18653/v1/2023.emnlp-demo.46. Джерело. Supports 15 English/Chinese datasets and mainstream event-understanding paradigms. Межа: Demonstration/toolkit paper; no Ukrainian or Russian performance established by claimed coverage.

13. Alon Eirew; Arie Cattan; Ido Dagan (2021). “WEC: Deriving a Large-scale Cross-document Event Coreference dataset from Wikipedia.” NAACL-HLT, 2498-2510. DOI 10.18653/v1/2021.naacl-main.198. Джерело. WEC-Eng created and efficient baseline outperforms earlier compared task results according to authors. Межа: Hyperlink-derived English dataset; not evidence veracity benchmark or direct transfer result.

14. Qingyu Tan; Hwee Tou Ng; Lidong Bing (2023). “Towards Benchmarking and Improving the Temporal Reasoning Capability of Large Language Models.” ACL, 14820-14835. DOI 10.18653/v1/2023.acl-long.828. Джерело. Evaluated closed-book, open-book and reasoning QA; temporal learning framework improved tested models. Межа: QA benchmark/model-specific; no proof RAG alone solves incident temporal reconstruction.

15. Thorne, James; Vlachos, Andreas; Christodoulopoulos, Christos; Mittal, Arpit (2018). “FEVER: a Large-scale Dataset for Fact Extraction and VERification.” NAACL-HLT. DOI 10.18653/v1/N18-1074. Джерело. 185445 claims; original joint evidence/label baseline 31.87%; artificial Wikipedia claims

16. Aly, Rami et al. (2021). “The Fact Extraction and VERification Over Unstructured and Structured information (FEVEROUS) Shared Task.” FEVER workshop. DOI 10.18653/v1/2021.fever-1.1. Джерело. 13 entries; winner joint score 27%, +9pp baseline
17. Schlichtkrull, Michael; Guo, Zhijiang; Vlachos, Andreas (2023). “AVeriTeC: A Dataset for Real-world Claim Verification with Evidence from the Web.” NeurIPS Datasets and Benchmarks. DOI 10.52202/075280-2842. Джерело. 4568 real claims, 50 fact-checking orgs; verdict kappa .619
18. Schlichtkrull, Michael et al. (2024). “The Automated Verification of Textual Claims (AVeriTeC) Shared Task.” FEVER workshop. DOI 10.18653/v1/2024.fever-1.1. Джерело. 21 submissions; winner 63% vs 11% baseline, joint score; known evidence-store leakage
19. Akhtar, Mubashara et al. (2025). “The 2nd Automated Verification of Textual Claims (AVeriTeC) Shared Task: Open-weights, Reproducible and Efficient Systems.” FEVER workshop. DOI 10.18653/v1/2025.fever-1.15. Джерело. Winner .3317 vs baseline .2023; metric changed; Table7 Spearman .404 coverage/.244 relevance
20. Ullrich, Herbert; Drchal, Jan (2025). “AIC CTU@FEVER 8: On-premise fact checking through long context RAG.” FEVER workshop. DOI 10.18653/v1/2025.fever-1.22. Джерело. Simple 2-step RAG winner on 23GB single GPU/<60s constraint
21. Dong, Xin Luna; Berti-Équille, Laure; Srivastava, Divesh (2009). “Integrating Conflicting Data: The Role of Source Dependence.” Proceedings of the VLDB Endowment 2(1),550-561. DOI 10.14778/1687627.1687690. Джерело. Bayesian source dependence improves truth discovery; shared true values do not alone imply copying
22. Lebo, Timothy; Sahoo, Satya; McGuinness, Deborah (editors) (2013). “PROV-O: The PROV Ontology.” W3C Recommendation. Джерело. Standard provenance; no truth or reliability guarantee
23. Schema.org community (2026). “ClaimReview.” Living schema specification accessed 2026-11-07. Джерело. Export vocabulary for fact-check review, not full provenance graph
24. Asai, Akari; Wu, Zeqiu; Wang, Yizhong; Sil, Avirup; Hajishirzi, Hannaneh (2024). “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection.” ICLR. DOI 10.48550/arXiv.2310.11511. Джерело. 7B/13B trained reflection tokens; qualitative benchmark gains; no UA/RU incident guarantee
25. Yan, Shi-Qi; Gu, Jia-Chen; Zhu, Yun; Ling, Zhen-Hua (2024). “Corrective Retrieval Augmented Generation.” arXiv version reviewed. DOI 10.48550/arXiv.2401.15884. Джерело. Retrieval-quality evaluator and corrective actions; tested four short/long-generation datasets
26. Kim, Elliot; Garg, Avi; Peng, Kenny; Garg, Nikhil (2025). “Correlated Errors in Large Language Models.” ICML. DOI 10.48550/arXiv.2506.07962. Джерело. 350+ models; conditional on both erring, same wrong answer 60% on one leaderboard
27. Cemri, Mert et al. (2025). “Why Do Multi-Agent LLM Systems Fail?.” arXiv preprint v3. DOI 10.48550/arXiv.2503.13657. Джерело. 1600+ traces, 7 frameworks, 14 failure modes; taxonomy human kappa .88
28. Gao, Tianyu; Yen, Howard; Yu, Jiatong; Chen, Danqi (2023). “Enabling Large Language Models to Generate Text with Citations.” EMNLP. DOI 10.18653/v1/2023.emnlp-main.398. Джерело. ALCE; on ELI5 even best systems lack complete citation support 50% of time
29. Min, Sewon et al. (2023). “FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation.” EMNLP. DOI 10.18653/v1/2023.emnlp-main.741. Джерело. Atomic support precision; ChatGPT 58% in biography study; precision-only limitations
30. Song, Yixiao; Kim, Yekyung; Iyyer, Mohit (2024). “VeriScore: Evaluating the factuality of verifiable claims in long-form text generation.” Findings EMNLP. DOI 10.18653/v1/2024.findings-emnlp.552. Джерело. Verifiable claim extraction over 8 tasks; 16 models, cross-task rankings not necessarily correlated
31. Wei, Jerry et al. (2024). “Long-form factuality in large language models.” NeurIPS. DOI 10.48550/arXiv.2403.18802. Джерело. SAFE ~16k facts, 72% crowd agreement; 76% wins on 100 disagreements; >20x cheaper
32. Fabbri, Alexander; Wu, Chien-Sheng; Liu, Wenhao; Xiong, Caiming (2022). “QAFactEval: Improved QA-Based Factual Consistency Evaluation for Summarization.” NAACL. DOI 10.18653/v1/2022.naacl-main.187. Джерело. 14% average improvement over prior QA metrics on SummaC; QA/NLI complementary

33. Farquhar, Sebastian; Kossen, Jannik; Kuhn, Lorenz; Gal, Yarin (2024). “Detecting hallucinations in large language models using semantic entropy.” Nature 630,625-630. DOI 10.1038/s41586-024-07421-0. Джерело. Mean AUROC .790 over 30 task/model combinations vs naive entropy .691; no guarantee against systematic confident errors

34. Quach, Victor; Fisch, Adam; Schuster, Tal; Yala, Adam; Sohn, Jae Ho; Jaakkola, Tommi; Barzilay, Regina (2024). “Conformal Language Modeling.” ICLR. Джерело. Calibrated stopping/rejection rules for output sets; guarantees depend on assumptions/calibration

35. Wang, Zhiyuan; Duan, Jinhao; Cheng, Lu; Zhang, Yue; Wang, Qingni; Shi, Xiaoshuang; Xu, Kaidi; Shen, Heng Tao; Zhu, Xiaofeng (2024). “ConU: Conformal Uncertainty in Large Language Models with Correctness Coverage Guarantees.” Findings EMNLP. DOI 10.18653/v1/2024.findings-emnlp.404. Джерело. Black-box conformal uncertainty; iid calibration condition

36. ACLED (2024). “ACLED Codebook; Fatalities.” Official operational methodology. Джерело. Event/sub-event and actor coding; date/location precision. Companion fatalities methodology: https://acleddata.com/methodology/fatalities distinguishes reported fatalities and uncertainty, codes unknown as zero and some unspecified deaths as 3 or 10. Межа: Not an automated scientific classifier. Conventions for database aggregation must not replace open-world individual-case evidence states.

37. Ali Hürriyetoğlu; Osman Mutlu; Erdem Yörük; Farhana Ferdousi Liza; Ritesh Kumar; Shyam Ratan (2021). “Multilingual Protest News Detection - Shared Task 1, CASE 2021.” CASE 2021, ACL, pp. 79-91. DOI 10.18653/v1/2021.case-1.11. Джерело. Four tasks: document classification, sentence classification, event sentence coreference, event extraction; best event extraction 66.20-78.11 F1-macro across settings. Межа: English/Portuguese/Spanish plus Hindi document evaluation; not a UA/RU Telegram validation.

38. Philip A. Schrodt and collaborators (2012). “CAMEO: Conflict and Mediation Event Observations Codebook.” Official Event Data Project codebook, version 1.1b3. Джерело. Actor-action-target descriptive political interaction taxonomy. Межа: Foundation before 2018; ontology is not evidence verification, and international interaction codes require local adaptation.

39. GDELT Project (2013). “GDELT Data Format Codebook.” Official technical documentation. Джерело. SOURCEURL points to a source article; a single URL is not all independent evidence. Межа: Version-specific legacy field semantics; machine-coded event output needs source-level validation.

40. Wei Wang; Ryan Kennedy; David Lazer; Naren Ramakrishnan (2016). “Growing pains for global monitoring of societal events.” Science 353(6307), 1502-1503. DOI 10.1126/science.aaf6758. Джерело. Discusses reliability and validity issues in global automated event systems ICEWS/GDELT. Межа: Foundational policy forum rather than contemporary model leaderboard.

41. Faniry A. Razakason; Daniel Racek; Paul W. Thurner; Göran Kauermann (2026). “Assessing Reporting Delays in ACLED Conflict Event Data.” arXiv preprint 2603.25964. DOI 10.48550/arXiv.2603.25964. Джерело. African weekly ACLED releases June 2024-June 2025; grouped proportional hazard analysis finds structured reporting delays, with more than half included within two weeks. Межа: Preprint; African event context does not calibrate Ukrainian social platform delays.

42. Doug McAdam; Sidney Tarrow; Charles Tilly (2001). “Dynamics of Contention.” Cambridge University Press. Джерело. Compares eighteen episodes, focusing on interaction mechanisms and changing actors/identities. Межа: Foundation before 2018; mechanisms cannot be inferred from keyword co-occurrence alone.

43. W. Timothy Coombs (2007). “Protecting Organization Reputations During a Crisis: The Development and Application of Situational Crisis Communication Theory.” Corporate Reputation Review 10, 163-176. DOI 10.1057/palgrave.crr.1550049. Джерело. Framework for crisis response and reputational threat. Межа: Foundation before 2018; text-only crisis analysis does not measure individual trust changes.

44. Grace Luo; Trevor Darrell; Anna Rohrbach (2021). “NewsCLIPpings: Automatic Generation of Out-of-Context Multimodal Media.” EMNLP 2021, 6801-6817. DOI 10.18653/v1/2021.emnlp-main.545. Джерело. Constructs genuine-image/genuine-caption mismatches, benchmarks multimodal detection under semantic/entity inconsistency. Межа: Automatically generated news pairs; not direct validation for conflict video/date/location.

45. Stefanos-Iordanis Papadopoulos; Christos Koutlis; Symeon Papadopoulos; Panagiotis C. Petrantonakis (2024). “VERITE: a Robust benchmark for multimodal misinformation detection accounting for unimodal bias.” International Journal of Multimedia Information Retrieval 13, article 4.

DOI 10.1007/s13735-023-00312-6. Джерело. Modality balancing exposes unimodal shortcuts; conclusion reports 52.1% multiclass accuracy. Межа: Real-world image-caption verification; not full video forensics. Journal publication January 2024, earlier preprint 2023.

46. Alec Radford; Jong Wook Kim; Tao Xu; Greg Brockman; Christine Mcleavey; Ilya Sutskever (2023). “Robust Speech Recognition via Large-Scale Weak Supervision.” ICML 2023, PMLR 202, 28492-28518. Джерело. 680,000 hours multilingual/multitask training with strong zero-shot benchmark transfer. Межа: Benchmark robustness is not factual certainty for UA/RU noisy field recordings.

47. Allison Koenecke; Anna Seo Gyeong Choi; Katelyn X. Mei; Hilke Schellmann; Mona Sloane (2024). “Careless Whisper: Speech-to-Text Hallucination Harms.” ACM FAccT 2024. DOI 10.1145/3630106.3658996. Джерело. 13,140 English audio segments; 1.4% yielded hallucination sequence in studied 2023 API runs. Межа: AphasiaBank English domain; not universal rate for every Whisper version or language.

48. Hervé Bredin (2023). “pyannote.audio 2.1 speaker diarization pipeline: principle, benchmark, and recipe.” Interspeech 2023. Джерело. Speaker segmentation, embeddings and agglomerative clustering; domain adaptation recipe. Межа: Anonymous speaker grouping is not biographical identity; noise/overlap and domain shift matter.

49. Matthijs Douze et al. (2021). “The 2021 Image Similarity Dataset and Challenge.” ISC2021 / arXiv:2106.09672, revised 2022. DOI 10.48550/arXiv.2106.09672. Джерело. Modified-copy retrieval in one million reference images with large distractor sets and challenging edits. Межа: Copy detection benchmark, not scene identity/geolocation/truth verification.

50. Jiaming Sun; Zehong Shen; Yuang Wang; Hujun Bao; Xiaowei Zhou (2021). “LoFTR: Detector-Free Local Feature Matching With Transformers.” CVPR 2021, 8922-8931. Джерело. Coarse-to-fine dense matching using self/cross attention; strong indoor/outdoor correspondence and localization benchmarks. Межа: Candidate match to an incorrect reference or repeated structure does not establish location.

51. Chen-Lin Zhang; Jianxin Wu; Yin Li (2022). “ActionFormer: Localizing Moments of Actions with Transformers.” ECCV 2022. DOI 10.1007/978-3-031-19772-7_29. Джерело. 71.0% mAP at tIoU=0.5 on THUMOS14; 36.6% average mAP on ActivityNet 1.3. Межа: Action labels/time intervals are not legal or causal interpretations of conflict.

52. PaddleOCR team (2025). “PaddleOCR 3.0 Technical Report.” arXiv preprint 2507.05595. Джерело. Separates PP-OCRv5 multilingual recognition, PP-StructureV3 parsing, PP-ChatOCRv4 extraction. Межа: Tool availability does not validate Ukrainian screenshots; local critical-field evaluation required.

53. Coalition for Content Provenance and Authenticity (2025). “C2PA and Content Credentials Explainer.” Official technical standard documentation, version 2.2. Джерело. Cryptographic content binding and provenance statements; explicitly states provenance alone cannot tell whether content is true/accurate/factual. Межа: Technical standard, not peer-reviewed truth classifier; manifest absence does not imply fabrication.

54. W3C. PROV-DM: The PROV Data Model and PROV-O: The PROV Ontology (2013). PROV-DM; PROV-O. Модель Entity/Activity/Agent та derivation; provenance interchange, а не оцінка істинності.

55. Schema.org. ClaimReview. Vocabulary; Google Search Central, Fact Check structured data. Схема публікації review, не фактчекінг-алгоритм.

56. Gao, T., Yen, H., Yu, J., & Chen, D. (2023). “Enabling Large Language Models to Generate Text with Citations.” EMNLP 2023, 6465–6488. DOI 10.18653/v1/2023.emnlp-main.398. ALCE, у тому числі incomplete citation support у найкращих оцінених моделях на ELI5 приблизно в половині випадків.

57. Huang, J. et al. (2024). “Large Language Models Cannot Self-Correct Reasoning Yet.” ICLR 2024. OpenReview. Intrinsic self-correction без зовнішнього feedback може не покращити й погіршити результат.

58. Pan, L. et al. (2024). “When Can LLMs Actually Correct Their Own Mistakes? A Critical Survey of Self-Correction of LLMs.” TACL 2024. ACL Anthology. Самокорекція вимагає зовнішньої надійної перевірки або спеціальних умов задачі.

59. Debenedetti, E. et al. (2024). “AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents.” NeurIPS 2024 Datasets and Benchmarks. Paper. 97 задач і

629 security test cases для tool-using agent evaluation.

60. Schlichtkrull, M. et al. (2024). “The Automated Verification of Textual Claims (AVeriTeC) Shared Task.” FEVER 2024. arXiv:2410.23850. Переможець 63% за специфічною спільною метрикою; не слід називати це 63% factual accuracy.

61. Verma, P. et al. (2025). “The Second Automated Verification of Textual Claims (AVeriTeC) Shared Task.” FEVER 2025. ACL Anthology, DOI 10.18653/v1/2025.fever-1.15. Переможець отримав joint score 0,3317; revised test усуває temporal leakage; evidence metrics лише помірно збігаються з людським судженням і можуть пропускати числові суперечності.

62. Liu, J., Thoma, S., & Rettinger, A. (2024). “FZI-WIM at AVeriTeC Shared Task: Real-World Fact-Checking with Question Answering.” FEVER 2024. ACL Anthology. Відкриті моделі та QA decomposition; результати демонструють роль retrieval/query decomposition, але також моделі мають обмеження.

63. C2PA. Technical Specification 2.2. Specification. Підписані provenance assertions перевіряються під певними trust assumptions; відсутній manifest не доводить фальшивість або автентичність контенту.

Узагальнення

Найнадійніша автономна система для Social — evidence-first pipeline із незмінними артефактами, атомарними твердженнями, passage-level evidence, source lineage, часовими інтервалами, версійованими статусами та формальними інваріантами. LLM допомагає витягувати структуру й готувати обмежену чернетку; її оцінка не є незалежним підтвердженням. Успішний звіт зберігає простежуване походження кожного емпіричного твердження й показує невідоме там, де доступний корпус не дає відповіді.